


딥러닝 기반 부실기업 예측 모형에 관한 연구

부실하체 트레이너

2025.06.09



1. 팀 소개

2. 논문 선정 이유

3. 서론 & 선행연구

4. 분석 흐름

5. Data Set & 전처리

6. 변수 설정

7. 모델링

8. 성능 결과 해석

9. 기여 효과


10. 한계점

부실하체 트레이너

부실(약점)은 그냥 숨기거나 외면하는 게 아니라,
근육처럼 “훈련과 데이터”로 단련시켜 강점으로 만들어주겠다.

부실하체 트레이너는 기업의 재무구조나 내실이 허약한 부분(=‘부실한 하체’)
을 데이터 분석과 인공지능 기법으로 진단하고,
근육 트레이너처럼 단련(=리스크 개선, 체질개선)하여 더욱 튼튼하고
내실이 건실한 기업들만 고를 수 있게 도움을 줄려고 합니다

김지훈, 김도현, 김보윤, 오대한, 정승원



1. 기존 부실기업 예측 연구의 한계 극복

- 전통적 부실기업 예측 연구는 주로 부도기업을 대상으로 하였으나, 부도기업은 이미 사업활동이 중단된 상태이므로 실질적으로 조기 경보 및 사전 관리가 어렵다는 한계가 있다.
- 본 연구는 실제 경영활동을 영위하고 있으나 재무적으로 취약한 ‘한계기업’(3년 연속 이자보상배율 1 미만)을 예측 대상으로 삼아, 실무적으로 더 유의미한 신용위험 조기경보 체계 구축에 기여한다.

2. 최신 머신러닝·딥러닝 기법의 실증적 적용

- 최근 회계·재무 분야에서 머신러닝, 특히 딥러닝 기법의 활용이 증가하고 있으나, 한계기업 예측에 딥러닝(RNN, CNN 등)을 적용한 국내 연구는 매우 드물다.
- 본 논문은 대규모 상장·비상장 기업 데이터를 활용해 RNN-LSTM, RNN-GRU, CNN 등 딥러닝 모델과 Random Forest, SVM 등 앙상블 머신러닝 모델을 비교·분석함으로써, 딥러닝의 실질적 효용성과 적용 가능성을 검증한다.

1. 한계기업(부실기업) 정의

- 한계기업은 사업활동을 지속하지만 재무구조가 부실하여, 추가 지원 없이 장기적으로 정상 경영이 어려운 기업을 의미.
- 국내에서는 3년 연속 이자보상배율(영업이익/총이자비용) 1 미만인 기업을 한계기업으로 정의(한국은행, 2016).
- 일본 등 해외에서는 ‘수익을 내지 못하고 차입금 의존도가 높아 외부 자금지원 없이는 파산 위험이 큰 기업’으로 정의 (Caballero et al., 2008).
- 기존 부도기업 예측 연구는 사업활동이 이미 중단된 기업을 대상으로 하여, 실무적으로 ‘관리대상’ 선별에는 한계가 있음. 이에 따라 계속기업 중 부실 징후가 있는 한계기업 예측의 중요성이 대두됨.

2. 부실기업 예측의 전통적 방법론

- 1960년대 이후 재무비율 기반 통계기법이 부실(부도)기업 예측에 활용됨.
- 대표적 방법:
 - 다중판별분석(MDA): Altman(1968)
 - 로지스틱 회귀: Ohlson(1980)
 - 프로빗 분석: Zmijewski(1984)
- 단점: 변수의 정규성, 독립성 등 엄격한 통계적 가정 필요. 입력변수 제약이 많고, 비선형·복잡한 데이터에는 한계가 있음.

3. 머신러닝 기반 부실기업 예측

- 1990년대 이후 인공신경망(ANN), 서포트 벡터 머신(SVM), 의사결정나무, K-최근접이웃(KNN) 등 다양한 머신러닝 기법 도입.
- 머신러닝은 전통적 통계기법 대비 더 높은 예측력을 보임(Odom & Sharda, 1990; 이건창, 1993; Shin et al., 2005; Kim & Sohn, 2010).
- 최근에는 비재무적 변수(예: 기업공시, 경영진 특성 등)와 결합한 연구도 증가.

4. 머신러닝 앙상블(Ensemble) 기법

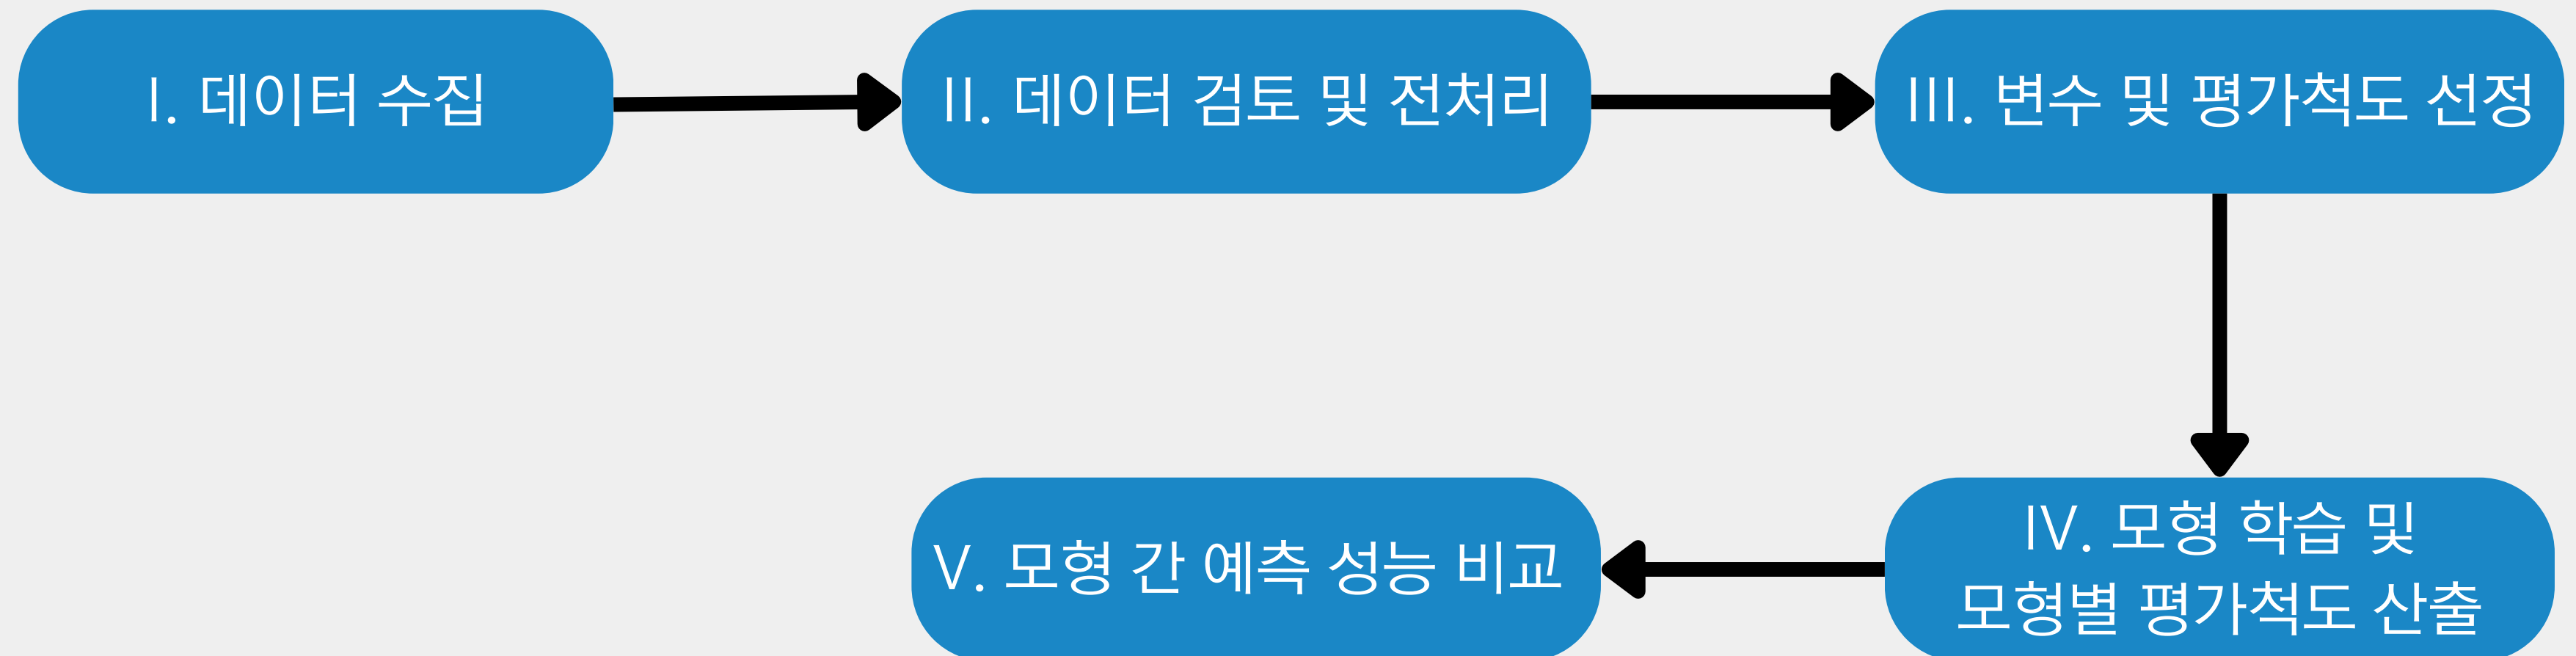
- 단일 분류기(Classifier)보다 예측 성능을 높이기 위해 앙상블 기법(Bagging, Boosting, Random Forest, Voting, Stacking 등) 활용.
- 선행연구에서 앙상블은 단일기법 대비 일관되게 우수한 성능을 보임(김승혁, 김종우, 2007; Barboza et al., 2017; 엄하늘 등, 2020).
- 선행연구에서 데이터 불균형 문제(부실기업 소수) 해결을 위해 SMOTE 등 오버샘플링 기법도 활용됨.

5. 딥러닝(Deep Learning) 기반 부실기업 예측

- 딥러닝은 다층 인공신경망(Deep Neural Network, DNN), 순환신경망(RNN: LSTM, GRU), 합성곱신경망(CNN) 등으로 구성.
- 대량·복잡한 데이터에서 주요 특성을 추출, 비선형적 관계를 효과적으로 학습.
- 최근 부실기업 예측에 RNN, LSTM, CNN 등 딥러닝 구조가 도입되어, 기존 머신러닝/통계기법 대비 더 높은 예측력 (특히 Recall 등 민감도 지표) 입증(Yeh et al., 2015; 차성재, 강정석, 2018; Mai et al., 2019; Hosaka, 2019).
- 기업 재무비율을 이미지화하여 CNN에 적용하거나, 시계열 재무데이터를 RNN-LSTM에 적용하는 등 다양한 방법론이 실증적으로 검증됨.

6. 실무적 시사점 및 최신 트렌드

- 예측대상: 부도기업이 아닌 한계기업(3년 연속 이자보상배율 1 미만)으로 확장, 실무적 활용성 제고.
- 데이터: 재무비율, 비재무정보, 시계열·이미지형 데이터 등 다양한 특성 반영.
- 모형 선택: 단일 통계/머신러닝보다 앙상블·딥러닝이 복잡한 패턴, 비선형 관계에 효과적.
- 평가 지표: Accuracy, Precision, Recall, F1 등 복수 지표로 성능 평가.
- 데이터 불균형: SMOTE 등 오버샘플링, 원저라이징 등 이상치 처리 필수.
- 설명가능성: XAI(설명가능 인공지능) 기법 적용 필요성 대두.



분석 대상 : 2017~2019년 KOSPI, KOSDAQ, KONEX 상장기업 및 외부감사 대상기업 16,813개
(16년 이후 설립 및 적정 감사의견 외 기업을 제외한 비금융업 업종의 12월 결산법인)

결측치 처리 : 중앙값으로 대체
(영업이익이자보상비율에서 결측치가 존재하는 경우 기업데이터 제거)

이상치 처리 : 윈저라이징(Winsorizing)을 통해 0.01, 0.99에 해당하는 값으로 변환

표본 : 한계기업 : 2017~2019년 영업이익이자보상비율 1 미만
정상기업 : 한계기업 이외의 기업
※ 2019년을 기준으로 3개년도의 영업이익이자보상비율이 1 미만인지 여부 판단

Dataset & 전처리

빅데이터를 활용한 디지털금융 전문가 1기

분석 대상 : 2017~2019년 KOSPI, KOSDAQ, KONEX 상장기업 및 외부감사 대상기업 16,813개
16년 이후 설립 및 적정 감사의견 외 기업을 제외한 비금융업 업종의 12월 결산법인

최종 분석 대상 기업

결측치 처리 : 중앙값으로 대체 적용 → 평균으로 대체하는 경우
(영업이익이자보상비율에서 결측치가 존재하는 경우 기업데이터 제거)

정상기업 : 13,818개

이상치 처리 : 윈저라이징(Winsorizing)을 통해 0.01, 0.99에 해당하는 값으로 변환

한계기업 : 2,995개

표본 : 한계기업 : 2017~2019년 영업이익이자보상비율 1미만

정상기업 : 한계기업 이외의 기업

※ 2019년을 기준으로 3개년도의 영업이익이자보상비율이 1 미만인지 여부 판단

선정된 후보 재무비율

구분	분류	명칭	산식
1	성장성	총자산증가율	$(\text{기말총자산}-\text{기초총자산})/\text{기초총자산}\times 100$
2		유동자산증가율	$(\text{기말유동자산}-\text{기초유동자산})/\text{기초유동자산}\times 100$
3		매출액증가율	$(\text{당기매출액}-\text{전기매출액})/\text{전기매출액}\times 100$
4		순이익증가율	$(\text{당기순이익}-\text{전기순이익})/\text{전기순이익}\times 100$
5		영업이익증가율	$(\text{당기영업이익}-\text{전기영업이익})/\text{전기영업이익}\times 100$
6	수익성	매출액순이익률	$\text{순이익}/\text{매출액}\times 100$
7		매출총이익률	$\text{매출총이익}/\text{매출액}\times 100$
8		자기자본순이익률	$\text{순이익}/\text{자기자본}\times 100$
9	활동성	매출채권회전율	$\text{매출액}/\text{매출채권}$
10		재고자산회전율	$\text{매출원가}/\text{재고자산}$
11		총자본회전율	$\text{매출액}/\text{총자본}$
12		유형자산회전율	$\text{매출액}/\text{총자산}$
13		매출액대매출원가	$\text{매출원가}/\text{매출액}\times 100$
14		매출액대판매관리비	$\text{판매관리비}/\text{매출액}\times 100$
15	안정성	부채비율	$\text{부채}/\text{자기자본}\times 100$
16		유동비율	$\text{유동자산}/\text{유동부채}\times 100$
17		자기자본비율	$\text{자기자본}/\text{총자산}\times 100$
18		당좌비율	$\text{당좌자산}/\text{유동부채}\times 100$
19		고정비율	$\text{고정자산}/\text{총자본}\times 100$
20		순운전자본비율	$\text{순운전자본}/\text{총자본}\times 100$
21		차입금의존도	$(\text{장기 및 단기차입금}+\text{사채})/\text{총자본}\times 100$
22		현금비율	$\text{현금예금}/\text{유동부채}\times 100$

재무비율은 기업의 재무제표에서 얻을 수 있는 회계정보를 바탕으로 산출되는 변수로, 부도기업 등 부실기업 예측을 위해 많은 연구에서 사용된 바 있다(이인로, 김동철, 2015,630).

외부감사를 받은 기업의 재무정보는 신뢰성이 높으며, 이 정보를 바탕으로 산출한 재무비율을 활용하면 모형 구축이 쉽고 비용 효율적일 뿐만 아니라, 재무제표 자체의 예측력 측면에서도 이론적·실무적으로 의미가 크다 (박종원, 안성만, 2014, 639).

재무비율은 상장기업과 비상장기업의 가치 평가에 공통적으로 사용할 수 있는 평가지표이자 투자자들의 재무적 의사결정에 있어 중요한 수단이라고 할 수 있다(김선배 등, 2016, 5).

최종 변수: t-test를 통해 정상/한계기업 간 유의미한 차이 있는 변수만 선정 → 로지스틱 회귀분석 → 후진제거법

2017년(11개)	유동자산증가율, 순이익증가율, 영업이익증가율, 매출총이익률, 자기자본순이익률, 총자본회전율, 매출액대판매관리비, 당좌비율, 고정비율, 차입금의존도, 현금비율
2018년(12개)	매출액증가율, 순이익증가율, 영업이익증가율, 매출액순이익률, 자기자본순이익률, 매출액대매출원가, 매출액대판매관리비, 부채비율, 유동비율, 자기자본비율, 당좌비율, 고정비율
2019년(11개)	유동자산증가율, 매출액증가율, 순이익증가율, 자기자본순이익률, 총자본회전율, 유형자산회전율, 유동비율, 자기자본비율, 고정비율, 순운전자본비율, 차입금의존도

머신러닝 앙상블

Random Forest

SVM 앙상블

KNN 앙상블

딥러닝

RNN-LSTM

RNN-GRU

CNN

공통 파라미터 (Bagging 방식 적용)

n_estimators: 50 (앙상블에 사용할 약한 학습기 수)

랜덤 포레스트

max_depth: 5 (의사결정나무의 최대 깊이)

min_samples_split: 10 (노드 분할을 위한 최소 데이터 수)

K-최근접 이웃법 앙상블 모형

metric: Euclidean (거리 추정 방식)

n_neighbors: 30 (참고할 근접 데이터 수)

서포트 벡터 머신 앙상블 모형

C: 2 (벌칙 모수)

kernel: Linear (커널 함수)

공통 파라미터 (Bagging 방식 적용)

epochs: 200

activation_function: ReLU (활성화 함수)

loss_function: Binary Crossentropy (손실 함수)

optimizer: Adam (옵티마이저)

Early Stopping 적용

RNN-LSTM, RNN-GRU

num_hidden_layers: 4 (은닉층 수)

units_per_cell: 128 (각 셀의 노드 수)

합성곱신경망 (CNN)

num_hidden_layers: 4 (은닉층 수)

filters: 128 (필터 크기)

pooling_layer: MaxPooling (특징 추출 기법)

dropout_rate: 0.25 (드롭아웃 비율)

평가척도

평가척도	산식
정확도 (Accuracy)	$\frac{TP + TN}{TP + TN + FP + FN}$
정밀도 (Precision)	$\frac{TP}{TP + FP}$
재현율 (Recall)	$\frac{TP}{TP + FN}$
F1-점수 (F1-Score)	$\frac{2(\text{재현율} \times \text{정밀도})}{(\text{재현율} + \text{정밀도})}$

성능 결과 해석

빅데이터를 활용한 디지털금융 전문가 1기

평가척도 \ 모형	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	F1-점수 (F1-Score)
Random Forest	0.9328	0.9481	0.9760	0.9618
SVM Ensemble	0.8186	0.8252	0.9610	0.8879
KNN Ensemble	0.8027	0.8277	0.9321	0.8768
RNN-LSTM	0.8212	0.8221	0.9986	0.9017
RNN-GRU	0.8259	0.8281	0.9938	0.9053
CNN	0.8236	0.8238	1.0000	0.9034

랜덤포레스트 모형이 재현율을 제외한 모든 평가척도에서 가장 우수한 예측 성능을 보임

재현율의 관점에서는 딥러닝 모형들의 성능이 머신러닝 앙상블 모형들 에 비해 우수한 것으로 나타남

기여 효과

학문적 관점

- 부실기업 예측에 딥러닝 모형 적용하여 유용성 검증
- 머신러닝 앙상블 모형들의 성능과 비교하여 딥러닝 모형들이 더 좋은 예측 성능을 가질 수 있음을 확인
- 딥러닝 모형이 부실기업 예측 분야에서 더욱 유용한 역할을 할 수 있는 가능성을 제시

실무적 관점

- 한계기업을 예측대상으로 우리나라의 경제 실정에 맞는 기업 부실화 연구를 수행
- 어떠한 특성을 가진 기업이 관리대상으로 분류되어야 하는지를 보였다는 점에서 기여점

결과

- 랜덤 포레스트가 정확도, 정밀도, F-1점수가 가장 우수한 예측 성능을 보여줌
- 재현율 관점에서 딥러닝 모형들이 우수한 성능
- 한계기업을 기준으로 했을 때 부실기업을 잘 예측할 수 있다는 것을 확인

저자 의견

재무비율만을 이용하여 예측

비재무정보(비정량적 정보) 미포함 → 예측력에 한계

회계정보만을 활용하여 한계기업을 예측

역사적 데이터이므로 기업의 주가와 같은 시장정보가 가지는 적시성, 미래지향성 등이 부족

일정한 기업 규모 이상의 외부감사 대상기업 및 상장기업만으로 구성

본 연구는 중소기업을 분석대상에 포함하지 않아 다소 편향된 연구결과를 제시할 가능성을 내포

우리 팀 의견

불균형 데이터 처리 미흡

선행연구에서는 부스팅 활용 → 본 논문은 배깅(Random Forest)만 사용

SMOTE, 오버/언더샘플링 등의 데이터 증강 기법 미사용

데이터 분할 방식의 문제

랜덤 7:3 분할은 시계열적 예측 목적에 부적합

Validation 전략의 부재 : 단순히 랜덤 7:3 분할만 언급, Cross-validation, Time-based CV 등의 검증 기법이 없거나 불분명

한계기업 정의의 협소함

‘3년 연속 이자보상배율 < 1’ 조건만 사용 → 부실기업의 다양한 유형(자본잠식, 부도 등)은 고려되지 않음

우리 팀 의견

연도별 재무비율 변수 선정의 일관성 부족

변수선택이 연도별로 다르지만, 이 차이를 모델링에서 어떻게 반영했는지 명확히 설명되지 않음

딥러닝의 블랙박스 특성 문제

예측 결과에 대한 해석 가능성 부족
→ XAI 기법을 적용할 수 있음

다중 공선성 문제

변수 간 상관관계 분석 또는 VIF 분석에 대한 내용이 없음

학습 데이터 기간이 너무 짧음

딥러닝이 가진 장점(시계열 정보 축적, 복잡한 패턴 학습 등)이 충분히 발현되었는지도 의문
→ 넓은 기간의 데이터를 수집하여 분석하면 더 좋은 결과가 나올 것으로 예상

Thank you.