



## 저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.


이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩士學位論文

딥러닝 LSTM을 활용한  
동적 자산배분 모형  
설계 및 성과 분석

Dynamic Asset Allocation Model Design and Performance  
Analysis Using Deep Learning LSTM



國民大學校 비즈니스IT專門大學院  
트레이딩시스템 專攻

朴 鐘 春

2020

딥러닝 LSTM을 활용한  
동적 자산배분 모형  
설계 및 성과 분석

Dynamic Asset Allocation Model Design and Performance  
Analysis Using Deep Learning LSTM

指導教授 최 홍 식

이 論文을 碩士學位 請求論文으로 提出함

2021 年 02 月

國民大學校 비즈니스IT專門大學院  
트레이딩시스템 專攻

朴 鐘 春

2020

朴鐘春 의

碩士學位 請求論文을 認准함

2021 年 02 月



審査委員長 김 선 웅 ①인

審査委員 최 흥 식 ①인

審査委員 안 현 철 ①인

國民大學校 비즈니스IT專門大學院

# 차 례

그림 차례	ii
표 차례	iii
국문 요약	iv
제 1 장 서론	1
1.1 연구의 배경 및 목적	1
1.2 연구의 내용 및 구성	3
제 2 장 이론적 배경	4
2.1 LSTM(LongShort-Term Memory) 모형	4
2.1.1 인공신경망(Artificial Neural Network)	4
2.1.2 순환신경망(Recurrent Neural Network)	5
2.1.3 LSTM	6
2.2 자산 배분 모형	9
2.3 동적 자산 배분 모형	10
2.3.1 모멘텀(Momentum)	10
2.3.2 상대 모멘텀(Relative Momentum)	10
2.3.3 절대 모멘텀(Absolute Momentum)	11
2.3.4 듀얼 모멘텀(Dual Momentum)	11
2.3.5 MPAA(Modified Protective Asset Allocation)	12
2.3.5.1 MPAA 특징	12
2.3.5.2 MPAA 전략 설명	14
제 3 장 제안 모형 및 실증 분석	17
3.1 연구 환경	17
3.2 제안 자산 배분 모형	17
3.3 LSTM 주가 예측 결과	24
3.4 시뮬레이션 결과	25
3.4.1 자산군 배분 비중 변경에 따른 시뮬레이션	26
3.4.2 고정 현금 비율 변경에 따른 시뮬레이션	30
3.4.3 상위 모멘텀 변경에 따른 시뮬레이션	34
제 4 장 결론 및 향후 연구	39
4.1 결론	39
4.2 향후 연구	39
참고 문헌	41
ABSTRACT	44

## 그림 차례

<그림 1> 인공신경망 구조 .....	4
<그림 2> RNN(Recurrent Neural Network)의 구조 .....	5
<그림 3> LSTM(LongShort-Term Memory)의 구조 .....	6
<그림 4> LSTM Cell 구조 .....	7
<그림 5> 모멘텀별 누적수익률 .....	13
<그림 6> 모멘텀별 연평균 수익률 .....	14
<그림 7> P-MPAA Process .....	18
<그림 8> 학습 및 예측 데이터 기간 .....	22
<그림 9> MPAA 및 P-MPAA 자산배분 전략 도식화 .....	23
<그림 10> 주식:대체투자:채권 = 1:1:1 누적수익률 비교 .....	27
<그림 11> 주식:대체투자:채권 = 2:1:2 누적수익률 비교 .....	28
<그림 12> 주식:대체투자:채권 = 3:1:3 누적수익률 비교 .....	29
<그림 13> 현금 비율 = 0.1 누적수익률 비교 .....	31
<그림 14> 현금 비율 = 0.5 누적수익률 비교 .....	32
<그림 15> 현금 비율 = 1 누적수익률 비교 .....	33
<그림 16> 상위모멘텀 30% 누적수익률 비교 .....	35
<그림 17> 상위모멘텀 50% 누적수익률 비교 .....	36
<그림 18> 상위모멘텀 70% 누적수익률 비교 .....	37
<그림 19> 상위 모멘텀 50% 종목 리밸런싱 투자 비중 .....	38

## 표 차례

<표 1> 자산군별 종목명 및 종목수 .....	15
<표 2> MPAA 계산 과정 예시 .....	16
<표 3> 선정된 ETF 및 대체지수 .....	19
<표 4> 입력 변수 및 출력 변수 .....	21
<표 5> LSTM 하이퍼 파라미터 .....	21
<표 6> 종목별 예측증가 및 실제증가 .....	24
<표 7> 시물레이션 자산군 배분 비중 변경값 .....	26
<표 8> 종목별 리밸런싱 투자 비중 .....	26
<표 9> 주식:대체투자:채권 = 1:1:1 성과비교 .....	27
<표 10> 주식:대체투자:채권 = 2:1:2 성과비교 .....	28
<표 11> 주식:대체투자:채권 = 3:1:3 성과비교 .....	29
<표 12> 고정 현금 비율 변경값 .....	30
<표 13> 현금 비율 = 0.1 성과비교 .....	31
<표 14> 현금 비율 = 0.5 성과비교 .....	32
<표 15> 현금 비율 = 1 성과비교 .....	33
<표 16> 상위 모멘텀 변경값 .....	34
<표 17> 상위 모멘텀 30% 성과비교 .....	35
<표 18> 상위 모멘텀 50% 성과비교 .....	36
<표 19> 상위 모멘텀 70% 성과비교 .....	37

## 딥러닝 LSTM을 활용한 동적 자산배분 모형 설계 및 성과 분석

박 중 춘

트레이딩시스템 전공

저금리의 장기화와 금융위기를 겪으며 자산 투자의 패러다임이 액티브 운용에서 패시브 운용으로 바뀌면서 ETF 시장의 급격한 성장을 가져왔다. 그중 저비용 경쟁력을 바탕으로 ETF를 활용한 자산 배분 전략인 EMP가 미국 및 유럽에서 자산관리의 대표적인 도구로 자리 잡았다. 국내 금융업계에서는 다수의 로보 어드바이저 업체들이 EMP를 기반으로 급격한 성장을 이루고 있으며, 이들은 EMP에 머신러닝, 딥러닝 등의 AI 기술을 접목하여 패시브 운용방식을 발전시키고 있다.

패시브 운용의 이론적 배경은 Markowitz의 현대 포트폴리오 이론을 기점으로 CAPM 자산 가격 결정 모형 등 다양한 효율적 시장이론으로 발전되었다. 그러나 금융시장에서 효율적 시장이론에 반하는 이상 현상들은 지속해서 관찰되었고, 이후 여러 실증 분석을 통해 모멘텀 현상은 대표적 이상 현상으로 자리 잡았다. 모멘텀에 관한 여러 연구 중 Systrader79와 이성규는 듀얼 모멘텀을 개선한 동적 자산 배분 모델 MPAA 전략을 선보였다. 그러나 MPAA 전략은 과거와 현재 시점에 계산된 모멘텀이 미래에도 이어질 것이라는 가정하에 출발한다. 이는 과거 추세가 미래로 이어지지 않는다면 예측된 값과 다른 결과를 가져올 수 있다는 문제점을 내포하고 있다.

이에 본 연구에서 딥러닝 모형 중 시계열 데이터에 적합한 LSTM 순환신경망을 활용하여 미래 주가를 예측함으로써 이를 개선하고자 한다. T 시점에서 LSTM을 활용하여 한 달 뒤( $T+1$ ) 주가를 예측한 후, 예측된 주가를 바탕으로 동적 자산 배



분 모델 MPAA 전략을 활용하여 포트폴리오를 구성하였다. 그 결과, 여러 시뮬레이션 분석을 통해 연구 모형이 동일가중으로 구성한 벤치마크 및 기존 MPAA 전략보다 Sharpe Ratio, MDD 등 여러 위험성과 지표에서 개선됨을 보였다.

키워드 : ETF, EMP, 딥러닝, LSTM, 동적 자산 배분, MPAA



## 제 1장 서론

### 1.1 연구의 배경 및 목적

2000년대 후반 글로벌 자산운용업계의 무게중심은 ‘액티브(Active) 운용’에서 ‘패시브(Passive) 운용’으로 트렌드 변화가 나타났다. 1980년대 이후 2000년대 중반까지 헤지 펀드(Hedge Fund)와 초대형 액티브 펀드의 성장이 진행되었다. 그러나 저금리의 장기화와 금융위기로 인해 자산 투자의 패러다임 변화 등으로 지속적인 알파(Alpha) 창출의 여력이 낮아지고, 패시브 펀드의 저비용 경쟁력을 기반으로 베타(Beta) 추종 전략의 매력도가 높아졌다.

투자 패러다임의 변화는 ETF(Exchange Traded Fund)의 급속한 성장을 가져왔다. ETF 시장이 성숙기에 들어서면서 기존의 ETF 투기적 단기거래에 국한되었던 매매패턴에서 벗어나 ETF를 활용한 구조화 상품 개발과 자산관리 및 자산 배분 등으로 ETF를 활용한 다양한 분야로 파생되었다.

그중 ETF를 활용하여 자산 배분하는 방법을 EMP(ETF Managed Portfolio)<sup>1)</sup>라 부른다. 이는 미국 및 유럽을 중심으로 자산 배분과 고객 자산관리에 대표적인 도구로 자리 잡았다. EMP는 ETF의 유동성, 환금성, 투명성 등의 장점으로 운용 리스크를 최소화한 자산 배분 포트폴리오 설계가 가능하고, 고객별 맞춤 포트폴리오 서비스가 가능하다는 점에서 자산관리 솔루션을 제공하는 매개체로 활용도가 증가하고 있다.

---

1) ETF Managed Portfolio는 자산의 50% 이상이 ETF 또는 ETN 등의 ETP(ETF+ETN)로 운용되는 포트폴리오를 의미한다.

국내 다수의 로보 어드바이저(Robo-advisor)<sup>2)</sup> 업체들도 EMP를 활용하고 있다. 고객별 위험성향과 목표수익률, 투자 가능 기간 등을 고려한 후, 내재되어 있는 알고리즘을 기반으로 ETF 포트폴리오 서비스를 제공하고 있다. 대표적인 로보 어드바이저 플랫폼으로는 AIM(에임), Boolileo(불릴레오), Fint(핀트), Fount(파운트), 쿼터백 운용 등이 있다.

로보 어드바이저의 사용 기술은 크게 인공지능(AI) 방식과 알고리즘 방식의 두 종류로 나눌 수 있다. 인공지능 방식은 머신러닝, 딥러닝을 통해 방대한 데이터를 사전에 학습한 후, 모델을 생성하여 해당 모델에 실시간 데이터를 적용하여 그 결과를 얻는 것이다. 알고리즘 방식은 발생할 수 있는 모든 상황들을 전문가가 사전에 직접 정의하고 제어 및 규칙화하여 통제화된 방식의 판단을 수행하도록 하는 것이다.

그중 빅데이터 분석을 기반으로 한 인공지능(AI) 방식은 기존의 알고리즘의 방식보다 진일보한 기술이라 평가받고 있다. 그러나 현재 대다수의 로보 어드바이저 업체들은 사전에 정의된 룰베이스 알고리즘 방식을 사용하고 있다. 향후 기술발전과 소비자들의 인공지능 수요에 따라 대다수의 로보 어드바이저 업체들은 알고리즘 방식에서 AI를 결합한 방식으로 변화할 것으로 판단된다.

따라서 본 연구에서는 인공지능의 한 분야인 딥러닝 기술과 ETF를 활용한 동적 자산 배분 모델을 접목하여 포트폴리오 비중을 변경함으로써 패시브 펀드의 베타 추종 전략은 유지하되, 인공지능을 활용한 액티브 운용으로 알파를 창출함을 목적으로 한다.

---

2) 로보 어드바이저(Robo-advisor)는 로봇(Robot)과 투자 자문을 의미하는 어드바이저(Advisor)의 합성어로서, 인공지능(AI), 빅데이터 알고리즘 등을 활용하여 고객의 자산 운용을 자문하고 관리해 주는 서비스를 의미한다.

## 1.2 연구의 내용 및 구성

본 연구에서는 딥러닝 모형 중 순환신경망(RNN)기반의 LSTM를 이용하여 주가를 예측하고, 예측된 주가를 바탕으로 모멘텀 기반의 MPAA<sup>3)</sup> 자산 배분 전략을 응용하여 포트폴리오를 구성한다. 예측된 주가를 활용한 포트폴리오(P-MPAA)<sup>4)</sup>와 기존 MPAA 전략, 동일비중 벤치마크와의 성과 비교를 통해 LSTM을 활용한 자산 배분 모형이 수익성, 변동성, Sharp Ratio, MDD 등 대부분 지표에서 더욱 개선되었음을 보이고자 한다.

본 연구의 내용 및 구성은 다음과 같다.

2장은 본 연구를 위해 선행 연구와 이론적 배경을 정리하였다.

3장은 본 연구에서 제안한 모형에 관한 구체적 설계 및 국내, 해외 국가 지수, 상품선물, 채권 ETF을 활용한 실증 분석 결과를 서술하였다.

4장은 실험을 통한 본 연구의 결론과 향후 연구 방향에 대하여 제시하였다.

---

3) MPAA(Modified Protective Asset Allocation)는 듀얼 모멘텀을 활용한 보호적 자산 배분인 PAA(Protective Asset Allocation)를 개선시킨 모형이다.

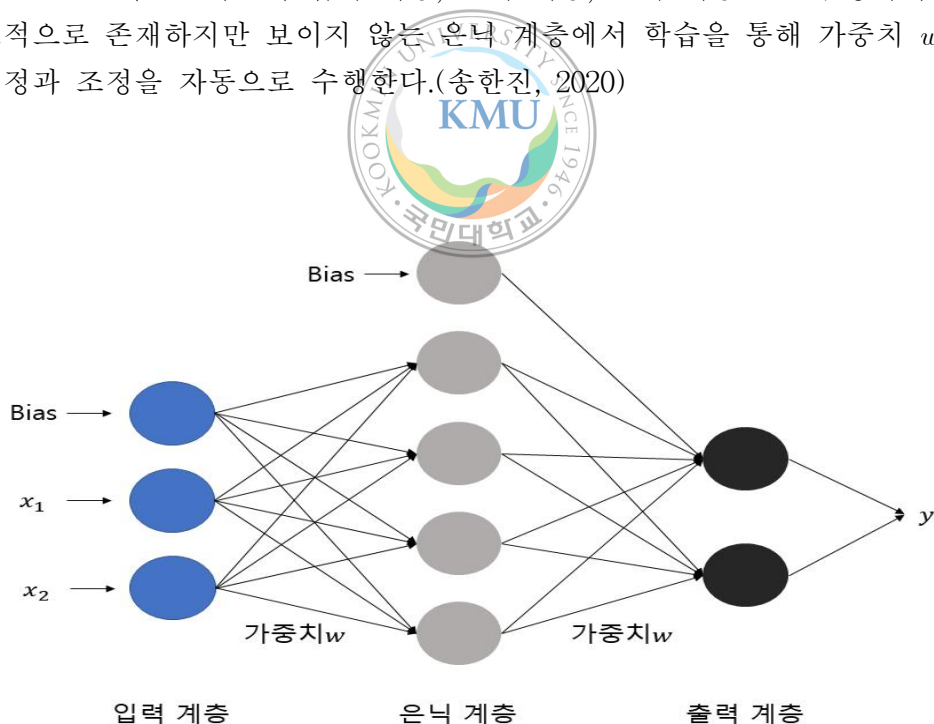
4) Prediction MPAA의 약자로 P-MPAA로 명한다.

## 제 2장 이론적 배경

### 2.1 LSTM(LongShort-Term Memory) 모형

#### 2.1.1 인공신경망(Artificial Neural Network)

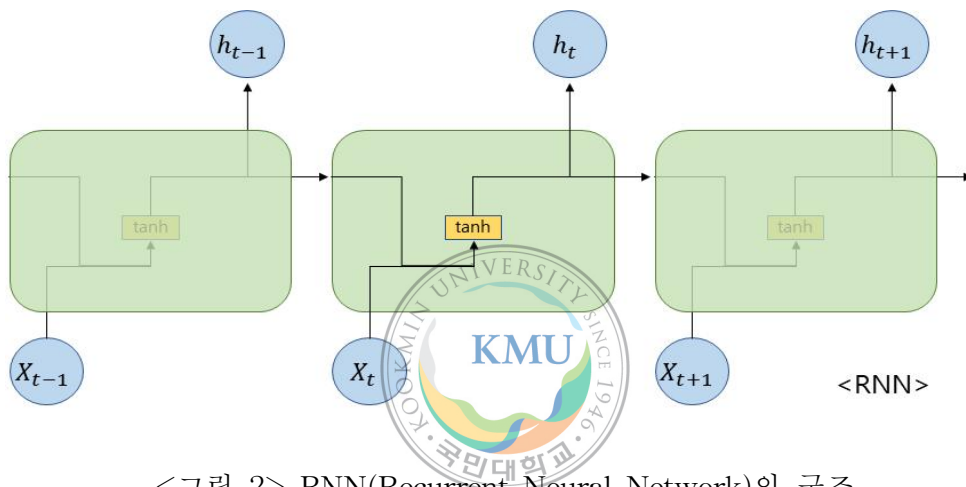
인공신경망은 인간의 뇌 신경세포 구조를 모방하여 컴퓨터로 구현한 머신러닝 알고리즘으로 입력 데이터와 출력 데이터에만 의존하여 스스로 가중치를 조정하며 학습한다. 따라서 통계를 기반으로 한 대부분의 분석 모델과 다르게 데이터에 가정이 필요하지 않아 접근성이 높다. 인공신경망은 일반적으로 <그림 1>과같이 입력 계층, 은닉 계층, 출력 계층으로 구성되며 구조적으로 존재하지만 보이지 않는 은닉 계층에서 학습을 통해 가중치  $w$ 의 설정과 조정을 자동으로 수행한다.(송한진, 2020)



<그림 1> 인공신경망 구조

### 2.1.2 순환신경망(Recurrent Neural Network)

순환신경망(RNN)은 인공신경망의 한 종류로 데이터가 순서를 가지고 있는 경우의 처리를 위해 순환적 구조를 갖고 있는 것으로 신경망 내부에 이전 출력값을 저장할 수 있는 모델이다.



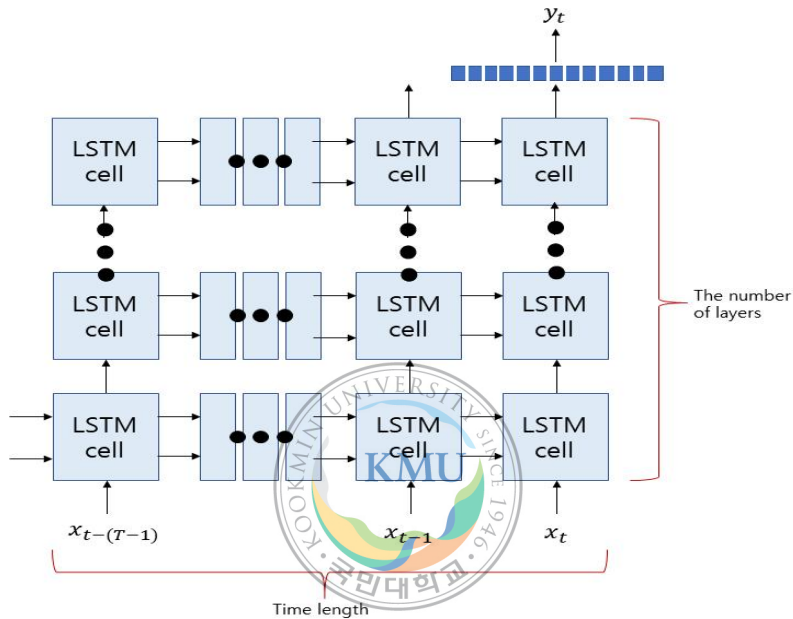
<그림 2> RNN(Recurrent Neural Network)의 구조

RNN은 하나의 tanh 혹은 Relu 활성화 함수를 가진 구조를 가지고 있다. <그림 2>와 같이 은닉 층에서 활성화 함수를 통해 나온 결과값을 출력 층과 다음 은닉 층 계산의 입력 값으로 보내는 특징을 갖는 것으로 과거의 학습 결과를 현재의 학습에 사용하는 딥러닝 네트워크이다. 이와 같은 특징으로 인해 시계열적인 특징을 갖고 있는 데이터를 처리하기에 적합한 알고리즘이다. 그러나 네트워크 체인이 길어질수록 과거의 학습 결과를 기억하지 못하는 장기 의존성 문제<sup>5)</sup>를 갖고 있다.

5) Time step이 길어질수록 앞쪽의 정보를 기억하지 못하는 문제. 역전파(Back Propagation)를 통해 오차를 줄여나가는 과정에서 미분을 이용함. Activation Function의 미분 값이 절댓값 1보다 작으므로 계속 곱하다 보면 0으로 수렴하여 앞부분의 정보는 결과값에 거의 영향을 미치지 못하게 된다.

### 2.1.3 LSTM


RNN의 장기 의존성 문제는 Hochreiter and Schmidhuber(1997)가 제안한 LSTM 알고리즘의 게이트(Gate)들을 사용함으로써 해결되었다.



<그림 3> LSTM(LongShort-Term Memory)의 구조

LSTM 순환신경망은 <그림 3>에서 나타난 것처럼 가로와 세로로 연결된 셀들과 최상단의 전결합레이어(Fully-connected layers) 구조로 이루어져 있다. LSTM 셀의 세로축 길이는 깊은 학습(Deep learning)을 위해 쌓은 LSTM 레이어 수를 의미하고 가로축 길이는 데이터를 추정하는데 필요한 입력의 시간 프레임 개수  $t$ 에 의해 결정된다. 시간 인덱스  $t$ 에 대해 길이  $N$ 의 특징 변수 프레임을  $x_t$ 라 할 때,  $T$ 개 셀들은 각각  $x_{t-(T-1)}$ ,  $x_{t-(T-2)}$ , ...,  $x_t$ 를 입력으로 받고 이전 셀의 출력과 셀 스테이트(Cell state)를 전달받아 업데이트하여 다음 셀에 전달한다. 이전 LSTM 레이어의 출력들은 다음 레이어의 입력으로 전달되고 마지막 LSTM 레이어 시간  $t$  셀의 출력은 최상단의 전결합레이어들을 통과하여 최종적으로 추정 값이 출력된다.(주형길과 이

기승, 2019)



<그림 4> LSTM Cell 구조

<그림 4>는 LSTM 순환신경망의 셀 내부를 나타낸 것이다. LSTM은 입력 자료에 대한 정보를 더욱 장기적으로 기억하기 위해 은닉층에 셀 상태 (cell state) 구조를 추가하였다. 망각 게이트( $f_t$ )는 바로 직전의 셀 상태를 얼마나 기억할지를 결정하고, 이전 단계의  $h_{t-1}$ 과 현재 단계의  $x_t$ 를 sigmoid 함수에 적용하여 0과 1사이의 값을 산정한다. 이를 현재 상태와 곱해지게 되며, 이 과정에서 정보를 유지할지 제거할지 결정한다.

$$f_t = \sigma(W_f \times [h_{t-1}, x_t] + b_f) \quad (1)$$

다음으로 앞으로 새롭게 들어오는 데이터 중 어떤 것을 셀 상태에 저장할 것인지를 정한다. 입력 게이트( $i_t$ )라고 불리는 시그모이드 함수가 어떤 데이터를 업데이트할지 정하게 된다. Hyperbolic tangent 함수를 통해 새로운 후보 값들인  $\tilde{c}_t$  벡터를 만들게 되고,  $i_t$  값과 조합하여 Cell State에 더한다.

$$i_t = \sigma(W_i \times [h_{t-1}, x_t] + b_i) \quad (2)$$



$$\tilde{C}_t = \tanh(W_c \times [h_{t-1}, x_t] + b_c) \quad (3)$$

과거 상태인  $C_{t-1}$ 을 업데이트해서 새로운 상태  $C_t$ 를 만들기 위하여, (식 1) ~ (식 3) 결과들을 이용한다. (식 4)를 통하여 현재 단계에 대한 정보 상태를 업데이트할 수 있다. 최종적인 결과는 출력게이트( $O_t$ )를 통해 수행될 수 있으며, 셀 상태의 어느 부분을 도출할지 결정하는 단계로 볼 수 있다. 이를 위해 (식 5)를 이용하며, 여기서  $b_o$ 는  $O_t$ 의 편향을 나타낸다. 마지막으로 (식 6)을 통하여 현재 셀 상태에 대한 업데이트를 수행한다.(김현일 외, 2020)

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t \quad (4)$$

$$O_t = \sigma(W_o \times [h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = O_t \times \tanh(C_t) \quad (6)$$

## 2.2 자산 배분 모형

자산 배분 모형은 분산 효과를 통해 포트폴리오의 비체계적 위험을 줄이고, 기대 수익을 높일 수 있는 계량화된 최적화 방법론이다. 포트폴리오 위험은 체계적 위험과 비체계적 위험으로 나눌 수 있다. 체계적 위험(Systematic risk)은 시장 전체의 변동 위험으로서 분산투자를 통하여 제거할 수 없는 위험을 뜻하고, 비체계적 위험(Unsystematic risk)은 전체적인 시장위험과는 관계없이 개별 기업에 영향을 주는 위험요인을 뜻한다.

현대 포트폴리오 이론(Modern Portfolio Theory; MPT)은 Markowitz(1952)가 'Portfolio Selection' 논문을 통해 포트폴리오 다각화를 수학적으로 풀어내면서 공식화하였다. 이후 Sharpe(1964)와 Linter(1965), 그리고 Mossin(1966)은 MPT를 토대로 체계적위험을 반영한 단일 요소 모델(single-factor model)인 자본 자산 가격 결정 모형(Capital Asset Pricing Model; CAPM)을 만들며 발전시켰고, Fama(1962)는 박사 학위 논문을 통해 효율적 시장이론(Efficient Market Theory)을 언급하며 '주가는 예측할 수 없다'는 결론을 내렸다. 이후 금융업계와 학계에서는 효율적 시장이론이 지배하면서 기술적 분석을 외면하였고, 모멘텀 투자 또한 간과하였다.

이후 수십 년 동안 시장 효율성에 반하는 가치 기반 증거들이 쌓여갔다. Fama and French(1993)는 CAPM의 단일 요인 모델을 시장요인 이외에 가치 요인, 규모 요인을 추가해 3요인 모델로 확장하였다. 바로 직후 Jegadeesh and Titman(1993)은 여전히 모멘텀 투자가 유효함을 밝혔고, 이후 Fama and French(1996)는 논문을 통해 대부분의 이례적 시장 현상은 없어졌지만, 모멘텀 효과를 인정하였다.

## 2.3 동적 자산 배분 모형

### 2.3.1 모멘텀(Momentum)

이후 20년간 널리 알려져 있던 합리적 가격 결정 모델들에 반하는 증거들이 나왔다. 모멘텀에 대한 다양한 실증 연구를 통해 모멘텀은 시장에서 관찰되는 대표적인 이상 현상(Anomaly)으로 자리 잡았다.

모멘텀이란 물리학의 개념을 도입한 것이다. 물리학에서 모멘텀은 물체의 질량과 속도의 곱으로 나타낸다. 예를 들어, 빠른 속도로 달리는 대형 화물차를 멈추기 위해서는 그와 반대로 작용하는 큰 힘을 한 번에 가하거나, 오랜 기간 일정한 힘을 가해야 한다. 이처럼 모멘텀 투자도 우수한 성과를 보인 자산군은 유의미한 역풍 없이는 이후에도 우수한 성과를 보일 것이라는 가정하에 투자하는 것이다.

즉, 모멘텀 투자란 매수와 매도를 최근의 수익률을 바탕으로 하는 투자 시스템이다. 모멘텀 투자자들은 우수한 성과를 보인 자산군을 매수하고, 저조한 성과를 보인 것은 매도하거나 피하면서 높은 수익률을 추구한다.

### 2.3.2 상대 모멘텀(Relative Momentum)

모멘텀 중 상대 모멘텀은 단면 모멘텀(Cross Sectional Momentum) 또는 상대 강도(Relative Strength)라고도 불린다. 이는 여러 자산 간의 수익률을 상대적으로 비교하는 것이다. 가장 기본적인 상대 모멘텀 투자법은 투자 유니버스 내에서 모멘텀이 가장 높은 N개를 리밸런싱 주기마다 순환하여 투자하는 것이다. 상대 모멘텀을 바탕으로 포트폴리오를 구성하면 자산군 내에서 수익률 관성이 높은 종목을 선택할 수 있다. Jeegadesh and Titman(1993)의 논문은 상대 모멘텀의 효과를 입증한 대표적인 논문이다. 1965년~1989년 미국 주식시장 데이터를 통해 최근 3~12개월간 모멘텀이 강한 종목을 매수하면 이후 상당한 초과수익을 얻을 수 있음을 입증하였다.

### 2.3.3 절대 모멘텀(Absolute Momentum)

절대 모멘텀은 시계열 모멘텀(Time-Series Momentum) 또는 추세추종(Trend Following)이라고 불린다. 이는 해당 자산의 현재 가격과 과거 가격을 비교하여 수익을 보이는 자산은 매수하고, 손실을 보는 자산은 피하는 전략이다. 상대 모멘텀의 경우 모든 자산군의 수익률이 마이너스(-)를 보인다면 그중 하락폭이 상대적으로 적은 자산을 매수하지만, 절대 모멘텀은 수익률이 음수인 자산은 매수하지 않거나 공매도를 한다는 차이점을 지니고 있다. Hurst, Ooi and Pedersen(2013)은 67개 시장에 1880년부터 2016년까지 137년에 걸친 백테스트를 통해 1, 3, 12개월의 절대 모멘텀 전략이 시장 대비 상당한 초과수익을 얻었음을 입증하였다.

### 2.3.4 듀얼 모멘텀(Dual Momentum)

듀얼 모멘텀은 상대 모멘텀과 절대 모멘텀을 혼합한 투자 전략이다. 예를 들어, 코스피200 종목 중 모멘텀이 높은 20종목을 상대 모멘텀을 통해 추출한다. 이후 절대 모멘텀을 활용하여 20종목 중 1년 전의 주가보다 현재 가격이 높은 종목만 선택하여 투자하는 것이 듀얼 모멘텀 투자 전략이다.

듀얼 모멘텀 개념은 Faber(2007)의 ‘A Quantitative Approach to Tactical Asset Allocation’ 논문을 통해 세상에 알려졌다. Faber는 상대 모멘텀으로 1, 3, 6, 12개월 모멘텀을 평균을 내서 상대 모멘텀 통합 순위를 구하여 사용하였고, 절대 모멘텀 기준으로 200일(10개월) 이동평균을 사용하였다. 이를 통해 절대 모멘텀, 상대 모멘텀을 각각 사용하는 것보다 두 전략을 혼합하여 사용하는 것이 연평균 수익률, MDD 등 성과 지표 측면에서 개선됨을 보였다. 이후 Gary Antonacci(2012)는 그의 논문과 듀얼 모멘텀(Dual Momentum) 제목의 책을 통해 듀얼 모멘텀의 명칭을 공식화하였고, 모멘텀 전략의 대중화를 이끌어 냈다.

우리나라 시장에 대한 실증 분석으로 차은아(2017)는 ‘한국 주식시장에서

시계열 모멘텀과 듀얼 모멘텀 전략에 대한 실증 연구'의 논문을 통해 한국 주식시장에서도 듀얼 모멘텀 전략이 각각의 전략보다 초과 수익률을 만든다는 점을 밝혔다.

### 2.3.5 MPAA(Modified Protective Asset Allocation)


이후에도 모멘텀을 활용한 전략은 학계와 현업에서 끊임없는 연구로 계속 발전하였다. Keller and Keuning(2016)은 논문을 통해 듀얼 모멘텀에 보호적 상수라는 개념을 도입하여 하락장에 안전자산인 채권 투자 비중을 늘림으로써 투자 성과를 개선한 보호적 자산 배분(Protective Asset Allocation; PAA) 모형을 제시하였다.

국내에서도 '실전 ETF 투자 매뉴얼'(2018)의 책을 통해 Systrader79, 이성규는 PAA를 개선한 수정된 보호적 자산 배분(Modified PAA; MPAA) 모형을 선보였다. 이는 추세 기반의 동적 자산 배분 모델로써, 기존에 널리 알려진 모멘텀 기반의 동적 자산 배분 모델의 단점을 개선한 전략이다.

#### 2.3.5.1 MPAA 특징

MPAA는 기존 동적 자산 배분 모델에 비해 크게 3가지를 개선했다. 첫째, 타임 프레임의 분산. 둘째, 횡보장에 대한 대비. 셋째, 시스템 스탑이다.


기존의 동적 자산 배분 모델은 상승 추세 또는 하락 추세를 판별하고, 절대 모멘텀의 기준을 특정 N개월 모멘텀으로 잡는다. 보편적인 동적 자산 배분 모델들은 앞선 논문에서 백테스트를 통해 검증된 특정 N개월을 모멘텀 기준점으로 사용한다. 다만, 특정 N개월을 사용하는 경우 테스트 기간이 다르거나, 백테스트 기간과 향후 시장 상황이 다르게 움직일 경우 최적의 값이 최악의 값으로 변할 수 있다는 과최적화 문제점을 내포하고 있다.



<그림 5> 모멘텀별 누적수익률

<그림 5>는 2002년 1월부터 2020년 8월까지 코스피200에 적용한 N개월 모멘텀별 누적수익률 그래프이다. 만약 동일 기간 동안 3, 5개월 모멘텀을 제외한 다른 모멘텀을 기준으로 사용했다면 Buy&Holding 전략보다 저조한 성적을 거두었을 것이다.

MPAA 전략은 특정 N개월 모멘텀 선택에 의한 과 최적화의 위험을 최소화하기 위해 1~12개월 평균 모멘텀을 사용한다. 평균 모멘텀의 장점은 <그림 6>에서 보듯이 여러 타임 프레임에 분산투자하여 장기적인 수익률의 편차를 상대적으로 적게 만들어, 향후 시장 상황이 바뀌어도 백테스트에서 나온 결괏값이 크게 바뀌지 않는다는 점이다.



<그림 6> 모멘텀별 연평균 수익률

두 번째 MPAA의 특징은 고정적인 현금비율을 설정함으로써 횡보장에 대한 대비책을 마련한 것이다. 기존의 모멘텀 전략들은 추세 추종 전략이기 때문에 하락장이 아닌 횡보장에서 손실이 누적되는 구조이다. MPAA는 추세 추종 전략을 구사하면서 고정적인 현금비율을 통해 100% 투자를 방지하여 위험관리 측면에서 우수한 성과를 보인다.

마지막으로 MPAA 전략에는 시스템 스탑을 통해 전체 포트폴리오의 손실을 제한하는 시스템을 도입한 것이 특징이다. 그러나 본 연구에서는 MPAA 전략이 아닌 LSTM을 활용하여 추가예측을 통한 자산 배분 성과 비교에 초점을 둔 만큼 해당 부분은 생략하여 분석하였다.

### 2.3.5.2 MPAA 전략 설명

MPAA 모델의 구체적인 로직을 예시를 들어 설명하면 다음과 같다. 자산 배분을 위해 <표 1> 같이 주식 10종목, 대체투자 5종목, 채권 3종목, MMF 1종목을 선정하였다.

<표 1> 자산군별 종목명 및 종목수

자산군	종목명	종목수
주식	코스피200, 코스닥, 다우산업, 나스닥 종합, 니케이225, 항생, 상해종합, 영국 FTSE100, 프랑스 CAC40, 독일 DAX	10
대체투자	금, 은, WTI원유, 구리, 천연가스 선물	5
채권	국고채 총수익 지수, IEF(7~10년물), TLT(20+년물)	3
MMF	KODEX 단기채권	1

### 1단계: 상대 모멘텀 적용(상위 30%)

매달 말 리밸런싱 시점마다 현금을 제외한 주식, 대체투자, 채권 군에 상대 모멘텀 전략을 적용한다. 각 자산군에 속한 개별 종목의 1~12개월 평균 모멘텀을 계산한 후, 평균 모멘텀이 높은 상위 30% 종목을 선정한다. 주식은 3종목, 대체투자는 2종목, 채권은 1종목을 선택한다.

$$N\text{개월 평균 모멘텀} = \frac{1}{N} \sum_{i=1}^N \frac{Price_{t-i}}{Price_t}$$

### 2단계: 절대 모멘텀 적용(현금 혼합)

절대 모멘텀을 적용하여 선택된 종목의 1~12개월 평균 모멘텀 스코어를 각각 계산한다. 계산된 평균 모멘텀 스코어와 고정 현금비율의 비를 계산하여 개별 종목의 투자 비중과 MMF 투자 비중을 결정한다. 이 과정에서 고정 현금 비율을 혼합하여 위험자산에 100% 투자되는 것을 사전에 방지하여 회보장에 대비책을 마련한다.

$$\text{종목별 투자비중}_i = \frac{\text{평균 모멘텀 스코어}_i}{\text{평균 모멘텀 스코어}_i + \text{현금 비율}}$$



$$N\text{개월 평균 모멘텀 스코어} = \frac{1}{N} \sum_{n=1}^N \begin{cases} 1, & n\text{개월 모멘텀}_i \geq 1 \\ 0, & n\text{개월 모멘텀}_i < 0 \end{cases}$$

$$MMF\text{ 투자비중}_i = \frac{\text{현금비율}}{\text{평균 모멘텀 스코어}_i + \text{현금비율}}$$

### 3단계: 자산군 배분 비중 적용 및 최종 투자비중 계산

투자자별 성향 및 시장 상황을 고려하여 주식, 대체투자, 채권 자산군의 배분 비중을 결정한다. 자산군별로 결정된 배분 비중을 2단계에서 계산된 종목별 투자 비중과 MMF 투자 비중에 각각 곱하여 종목별 최종 투자 비중을 결정한다.

최종 투자 비중이 결정되는 과정을 <표 2>의 예시를 통해 살펴보면, 자산군별로 배분 비중을 1:1:1로 할당하였고, 1단계에서 각 자산군마다 상대 모멘텀에 의해 코스피200, 코스닥, 나스닥 종합, 금, IEF을 선정하였다. 2단계에서 평균 모멘텀 스코어와 고정 현금비율(0.5)을 혼합한 절대 모멘텀을 적용하여 종목별로 최종 투자 비중을 산정하였다. MMF의 투자 비중은 모든 종목의 최종 투자비중을 결정한 후, 차액으로 계산할 수 있다.

<표 2> MPAA 계산 과정 예시

자산군	자산군 배분 비중	선정 종목	평균 모멘텀 스코어	고정 현금 비율	최종 투자비중	
주식	1	코스피200	0.75	0.5	$1/3 \times 1/3 \times 0.75/(0.75+0.5) =$	6.7%
		코스닥	1		$1/3 \times 1/3 \times 1/(1+0.5) =$	7.4%
		나스닥 종합	0.5		$1/3 \times 1/3 \times 0.5/(0.5+0.5) =$	5.6%
대체 투자	1	금	0.8		$1/3 \times 1/2 \times 0.8/(0.8+0.5) =$	10.3%
		WTI 원유	0.9		$1/3 \times 1/2 \times 0.9/(0.9+0.5) =$	10.7%
채권	1	IEF	0.6		$1/3 \times 1/1 \times 0.6/(0.6+0.5) =$	18.2%
MMF	-	KODEX 단기채권	-		$1 - \sum_{i=1}^6 \text{개별종목 투자비중}_i$	41.1%

## 제 3장 제안 모형 및 실증 분석

### 3.1 연구 환경

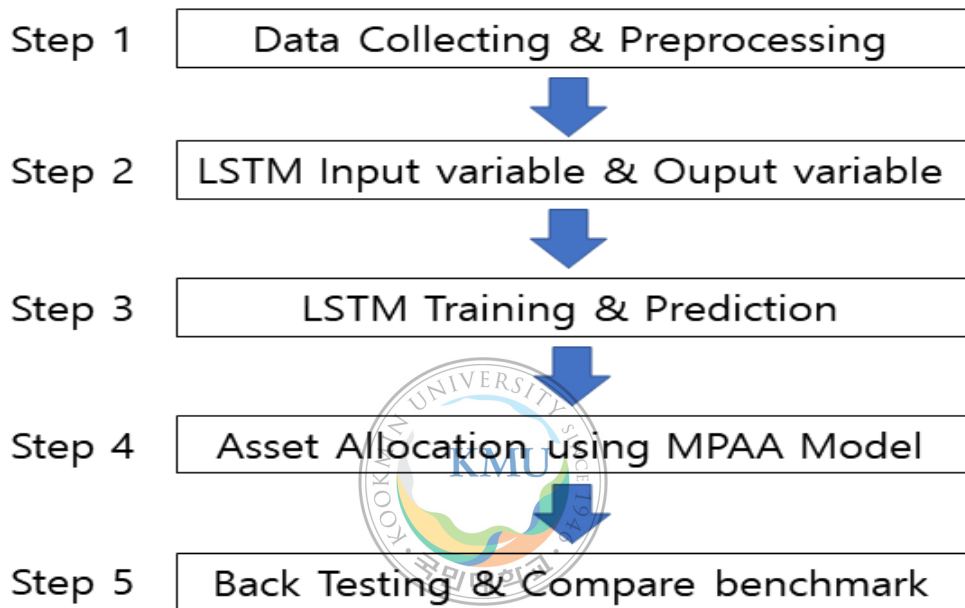
Python은 LSTM을 포함한 인공신경망 등의 기계학습을 수행하는 데 가장 최적의 프로그램 언어이다. Python의 대표적인 특징으로는 첫째, 다른 언어에 비해 쉬워 비교적 접근성 높은 언어이다. 둘째, 기계학습에 필요한 다양한 라이브러리가 구현되어 있어 사용이 편리하고 기계학습 시 가장 주류가 되는 언어이다. 본 연구에서도 Python 3.7.6 버전을 사용하여 LSTM의 학습 및 예측을 수행하였다. 구동 환경으로는 Jupiter Lab을 이용하였고, 기계학습에 사용한 라이브러리는 Tensorflow 2.2와 Keras를 사용하였다. 이외의 연구 환경은 다음과 같다.

- ① CPU - Inter(R) Core(TM) i5-3470 CPU @ 3.20GHz
- ② RAM - 12.0GB
- ③ OS - Windows10 x64bit
- ④ GPU - NVIDIA GeForce GT 620
- ⑤ Mainboard - SAMSUNG\_DT1234567890

### 3.2 제안 자산 배분 모형

본 연구에서 제안하는 자산 배분 모형에서는 예측 모형으로 순환신경망의 한 종류인 LSTM을 사용하여 각 종목의 한 달 뒤 주가를 예측하고, 예측된 주가를 바탕으로 MPAA 자산배분 전략을 실행한다. 연구 모형을 예측된 주

가를 활용하여 MPAA 자산배분 전략을 활용하므로 P-MPAA(Prediction-Modified Protective Asset Allocation)라 하였다. 아래의 <그림 7>와 같이 5단계 절차를 통해 구현하였다.



<그림 7> P-MPAA Process

### 1단계: 데이터 선정

본 연구는 국·내외 상장된 ETF를 활용하여 실제 투자에서도 활용될 수 있는 글로벌 자산 배분의 설계를 목적으로 두고 있다. 실제 ETF 데이터를 활용하여 분석하는 것이 최적의 조건이지만, 구할 수 있는 ETF 데이터의 기간이 짧아 시뮬레이션에 한계가 존재한다. 따라서, 본 연구에서는 장기간의 LSTM 지도학습과 백테스팅(Back-Testing)을 진행하기 위해 ETF 별로 대체 지수를 선정하여 분석하였다.

글로벌 자산 배분을 위해 주식 군, 대체투자 군, 채권 군, MMF 군으로 총 4개의 자산군으로 나누었다. 주식 군에는 총 10개의 국가지수, 대체투자 군에는 총 5개의 원자재 선물, 채권 군에는 총 3개의 국고채 총수익 지수와 ETF, MMF 군에는 1개의 ETF를 사용하였다. 선정된 ETF와 백테스팅을 위해 사용한 대체 지수는 <표 3>과 같다.

<표 3> 선정된 ETF 및 대체지수

자산군	종목명	상장일	총보수 (%)	대체지수	상관계수 (상장일 이후)	상장국가
주식	KODEX 200	2002/10/14	0.15	코스피 200	0.9997	한국
	KODEX 코스닥 150	2015/10/01	0.25	코스닥	0.9605	
	TIGER 미국다우존스30	2016/07/01	0.35	다우산업	0.9610	
	TIGER 미국나스닥100	2010/10/18	0.49	나스닥 종합	0.9917	
	KINDEX 일본Nikkei225(H)	2016/03/03	0.3	니케이 225	0.9913	
	KBSTAR 차이나HSCEI(H)	2016/08/10	0.4	항셍	0.9770	
	SMART 중국본토 중소형 CSI500(합성H)	2015/06/08	0.6	상해종합	0.8873	
	Franklin FTSE United Kingdom ETF	2017/11/02	0.09	영국 FTSE 100	0.9347	미국
	iShares MSCI France ETF	1996/03/12	0.5	프랑스 CAC 40	0.9239	
	WisdomTree Germany Hedged Equity Fund	2013/10/17	0.48	독일 DAX	0.8775	
대체 투자	KODEX 골드선물(H)	2010/10/01	0.68	금 선물	0.9438	한국
	KODEX 은선물(H)	2011/07/18	0.68	은 선물	0.9831	
	TIGER 원유선물 Enhanced(H)	2010/08/02	0.7	WTI원유 선물	0.9625	
	KODEX 구리선물(H)	2011/03/15	0.68	구리 선물	0.9585	
	United States 12 Month Natural Gas Fund	2009/11/18	0.9	천연가스 선물	0.7803	미국
채권	KODEX 국고채3년	2009/07/29	0.15	국고채 총수익 지수	0.9610	한국

	iShares 7-10 Year Treasury Bond ETF	2002/07/22	0.15	동일종목	1	미국
	iShares 20+ Year Treasury Bond ETF	2002/07/22	0.15	동일종목	1	
MMF	KODEX 단기채권	2012/02/22	0.15	동일종목	1	한국

대부분의 종목은 상관계수가 0.9를 넘었으나, 일부 종목에서는 0.7~0.8의 상관계수를 보였다. 이는 기초자산과 대체 지수의 구성종목의 차이, ETF 추적오차(Tracking Error), 괴리율의 차이로 판단된다. 장기간의 데이터가 필요하므로 불가피하게 대체 지수를 사용했다.

대체 지수의 데이터는 2001년 1월부터 2020년 8월까지 총 236개의 월간 데이터를 사용했다. 대부분의 데이터는 FnGuide의 데이터 프로그램인 DataGuide 5을 사용하여 수집하였다. 대체 지수를 사용하지 않은 해외채권 2종목, MMF 1종목은 Investing.com에서 수집하였다.

## 2단계: LSTM 입력변수 및 출력변수

본 모형에서 사용한 입력 변수는 대체 지수와 동일하게 DataGuide 5를 사용하여 수집하였다. MPAA 모델 특성상 MMF의 투자비중은 국가, 대체투자, 채권 군의 투자 비중이 결정되고, 이후 차액으로 결정된다. 따라서 MMF는 LSTM을 활용하여 예측할 필요가 없으므로 MMF를 제외한 총 18개 종목에 필요한 입력 변수와 출력 변수는 다음과 같다.

<표 4>와 같이 총 6개의 입력 변수를 사용하였다. 출력 변수로는 1개월 뒤의 증가를 예측하였다. 예외적으로, 국고채 총수익 지수의 경우 아래와 동일한 입력 변수를 얻을 수 없었다. 국고채 총수익 지수는 입력 변수로 평균증가, 평균 듀레이션, 평균 Convexity, 평균 YTM(%), 전월대비 수익률, 증가를 입력 변수로 사용하였다.

<표 4> 입력 변수 및 출력 변수

	변수명	설명
1	입력 변수	Open
2		Close
3		Low
4		High
5		Average Close
6		Rate of return
7	출력 변수	Target_Close

각 종목별로 학습 및 예측을 수행하기 위한 LSTM 모형의 하이퍼 파라미터는 <표 5>와 같다.


<표 5> LSTM 하이퍼 파라미터

하이퍼 파라미터	설정 값
Optimizer	Adam
Activation Function	tanh
Dropout	0.1
Epoch	5000
Batch Size	5
Learning_rate	0.01
Sequence_length	5

LSTM의 최적화기(Optimizer)로는 오차 감소 속도가 빠른 아담(Adam) 최적화기를 사용하였고, 활성화 함수는 하이퍼볼릭 탄젠트(Hyperbolic tangent)를 사용하였다. 또한, Learning rate는 0.01로 설정하고, 5000번의 반복적인 지도학습 시 과적합(Overfitting) 방지를 위해 Dropout 비율을 0.1로 두었다.


### 3단계: LSTM 학습 및 예측

LSTM을 포함한 지도학습모델의 경우, Train set과 Test set의 비율을 7:3으로 구성하는 것이 보편적이다. 본 연구에서는 전체 데이터 기간의 70%인 2001년 1월 ~ 2014년 9월은 Train set으로 설정하였고, 나머지 30%인 2014년 10월 ~ 2020년 8월은 Test Set으로 설정하였다. <그림 8>는 LSTM 학습 및 예측 데이터 기간을 도식화하여 나타낸 것이다.



### 4단계: 예측 주가를 활용하여 P-MPAA 전략 적용 및 투자비중 조정

본 연구에서는 Python을 이용하여 LSTM 학습모델과 시뮬레이션 알고리즘을 구현한 후, 예측된 주가를 바탕으로 P-MPAA 전략을 실행하였다. 연구에서 사용한 P-MPAA 전략은 기존 MPAA와 평균 모멘텀 스코어를 결정하는 과정에서 차이가 존재한다.



<그림 9> MPAA 및 P-MPAA 자산배분 전략 도식화

<그림 9>는 MPAA와 P-MPAA의 평균 모멘텀 스코어를 계산하는 과정을 나타낸 것이다. MPAA는 현재 시점의 결정된 증가를 기준으로 과거 1~12개월의 증가와 비교하여 평균 모멘텀 스코어를 계산한 후, 한 달 뒤에도 추세가 이어질 것으로 가정하여 투자 비중을 산정한다. 이와 달리 P-MPAA는 LSTM 모델로 한 달 뒤의 증가를 예측하고, 예측된 증가를 기준으로 선정된 뒤, 이번 달 증가 및 11개월 증가와 비교하여 평균 모멘텀 스코어 계산을 통해 투자 비중을 산정한다. 이 경우 LSTM의 예측력이 우수하다면 미래의 추세를 사전에 파악하여 시장 상황에 맞게 투자 비중을 조절할 수 있다는 장점이 있다.

#### 5단계: 제안 모형 백테스팅 및 MPAA, 벤치마크와 성과 비교

앞서 언급한 것처럼 본 연구에서는 전체 데이터 기간의 70%인 2001년 1월



~ 2014년 9월은 Train set으로 설정하였고, 나머지 30%인 2014년 10월 ~ 2020년 8월은 Test Set으로 설정하였다. 예측 증가를 구할 수 있는 기간은 Test period인 2014년 10월 ~ 2020년 8월이다. 해당 기간 동안 매달 말 리밸런싱을 가정하여 P-MPAA를 기존 MPAA 및 19개 자산을 동일비중으로 투자한 동일비중 벤치마크와 성과 비교를 하고자 한다.

### 3.3 LSTM 추가 예측 결과

<표 6>과 같이 MMF를 제외한 주식 군 10개, 대체투자 군 5개, 채권 군 3개 종목에 개별적으로 LSTM 모델을 적용하여 1개월 뒤 증가를 예측하였다. 입력 변수로는 위에서 언급한 6개의 입력값과 하이퍼 파라미터를 사용하였다.

<표 6> 종목별 예측증가 및 실제증가

	코스피200	코스닥	대우산업	나스닥 종합	나스닥225	원생	신세계	한국FTSE100	프랑스CAC40	독일DAX40	금 선물	은 선물												
Date	예측 증가	실제 증가	예측 증가	실제 증가	예측 증가	실제 증가	예측 증가	실제 증가	예측 증가	실제 증가	예측 증가	실제 증가												
2014-10-31	258.5695	250.45	592.8633	558.7	1771.08	1739.52	4537.454	4630.74	16338.25	16413.76	2402.527	29998.06	2298.316	3420.16	6915.82	6546.47	4504.26	4233.09	9503.523	9326.87	1342.738	1295.9	13.08411	16.08
2014-11-30	249.3821	253.7	554.0366	545.08	16974.48	17828.24	4511.32	4791.63	16823.82	17459.95	23418.53	23807.95	23569.95	2682.83	6701.073	6722.62	4183.727	4390.16	9241.388	9980.85	1255.076	1291.2	16.55145	14.76
2014-12-31	249.1407	244.05	528.1915	542.97	18149.94	17823.07	4773.452	4736.05	18151.1	17450.77	23527.85	23605.04	2599.893	3234.68	6925.299	6566.049	4132.089	4272.75	9763.097	9805.55	1238.811	1335.4	17.00788	15.57
2015-01-31	228.9703	249.88	532.3618	591.58	17451.96	17164.95	4681.721	4635.24	19189.72	17674.39	23302.54	24507.05	2997.668	3210.36	6582.335	6749.4	4132.208	4604.25	10298.7	10694.32	1304.164	1384.6	17.08351	17.19
2015-02-28	234.572	251.46	598.7796	624.56	17676.64	18132.7	4768.553	4963.53	19144.21	18797.94	24677.75	24823.29	3097.903	3310.3	6884.319	6946.66	4563.763	4951.48	10624.62	11401.66	1361.382	1309.4	18.04046	16.51
2015-03-31	234.3229	257.28	640.8922	650.49	17990.62	17776.12	4905.72	4900.88	20478.52	19206.99	25429.38	24900.89	3402.877	3747.9	7016.604	6773.04	4912.474	5033.64	11125.63	11966.17	1318.509	1272.2	15.24264	16.58
2015-04-30	242.0112	266.42	657.8332	689.01	17874.55	17840.52	4891.703	4941.42	20140.46	19520.01	24856.93	28133	4038.346	4441.66	6843.608	6960.63	5022.73	5046.49	12453.87	11454.38	1272.179	1273	14.6669	16.12
2015-05-31	254.9142	260.39	680.7366	711.39	18093.05	18010.68	5004.022	5070.02	21434.63	20563.15	27593.06	27424.19	4415.98	4611.74	7176.632	6984.43	5196.367	5007.89	12101.59	11413.82	1268.183	1280.7	16.2899	16.7
2015-06-30	259.5634	252.27	719.3827	742.27	18052.27	17619.51	5092.762	4986.87	21831.96	20235.73	27454.37	26250.03	4579.1	4277.22	7060.052	6520.98	5245.69	4790.2	11570.18	10944.97	1280.399	1270.8	17.08551	15.55
2015-07-31	263.5772	244.3	759.5853	725.06	17728.45	17689.86	5016.255	5128.3	21203.49	20585.24	26111	24636.28	4279.239	3663.73	6686.002	6696.28	5052.802	5082.61	12332.23	11308.99	1271.588	1183.1	15.85111	16.01
2015-08-31	250.97	232.8	740.4323	687.11	17866.69	16528.03	5098.291	4776.5	21417.05	18890.48	23553.29	21670.58	3991.109	3205.99	7060.22	6247.94	5201.38	4652.95	12017	10259.46	1204.881	1216.9	14.04339	15.81
2015-09-30	220.6696	236.71	705.658	678.48	15979.02	162847	4526.798	4620.2	19879.31	17388.15	19673.51	20846.3	2986.232	3052.78	6363.122	6061.61	4902.769	4455.29	11003.89	9680.44	1201.423	1183.6	14.6517	15.66
2015-10-31	217.9969	249.41	608.6728	683.63	16965.7	17663.54	4699.405	5053.7	17350.61	19083.1	19881.48	22640.04	2297.043	3382.56	5941.461	6361.09	4722.681	4897.66	10853.57	10850.14	1190.421	1195.2	14.83115	16.73
2015-11-30	216.8482	244.24	631.7445	688.38	17197.09	17719.92	4901.21	5108.7	20296.17	19747.47	21727.51	21996.42	2813.731	3445.4	6703.34	6356.09	5118.885	4957.6	11051.57	11382.23	1193.686	1123.9	16.12751	15.2
2015-12-31	227.4196	240.38	655.0892	682.35	17928.96	17425.03	5181.643	5007.4	20278.33	19033.71	21556.22	21914.4	3396.003	3538.18	6326.664	6242.32	5070.104	4637.06	12487.45	10743.01	1146.687	1121	14.81565	14.85
2016-01-31	238.8061	232.1	680.2765	682.8	17346.71	16466.3	5094.388	4614	20698.02	17518.3	24219.67	19683.11	3242.751	2737.6	6302.279	6083.79	4737.641	4417.02	11640.58	9788.11	1108.314	1161.9	12.2824	14.25
2016-02-29	238.4372	234.63	694.8462	651.62	16143.43	16516.5	4492.148	4557.95	19537.63	16026.76	20433.82	19119.3	3630.626	2687.98	6237.191	6097.09	4552.412	4353.55	11312.64	9495.4	1150.413	1273.3	13.75415	15.71
2016-03-31	237.7179	245.86	654.7944	688.38	16668.48	17685.09	4437.414	4889.85	14533.57	16758.67	17956.58	20776.7	2208.502	3003.92	5806.127	6174.9	4416.49	4385.06	11407.55	9965.51	1249.878	1280.9	16.39111	16.35
2016-04-30	238.9524	245.2	655.9055	699.77	17528.28	17773.64	4698.312	4775.36	17012.67	16666.05	20592.37	21067.05	2384.9	2938.32	6267.378	6241.89	4508.777	4428.96	10726.88	10338.97	1259.995	1341.4	17.16978	18.73
2016-05-31	238.9132	243.63	650.7132	698.45	18012.58	17787.2	4880.212	4948.06	15615.45	17234.98	20011.74	20815.09	2384.346	2916.62	6467.532	6230.79	4375.934	4505.62	10202.86	10262.74	1286.501	1269.3	17.16769	16.94
2016-06-30	241.809	244.14	708.9812	675.09	17845.27	17929.99	5116.387	4842.67	17551.66	15575.92	23859.82	20794.37	2802.314	2929.61	6343.038	6504.33	4515.102	4237.48	11432.21	9680.09	1258.324	1375	17.43261	19.52
2016-07-31	246.219	251.48	641.574	706.24	17779.46	18432.24	4794.628	5162.13	16165.94	16589.27	22009.8	21891.37	3239.075	2979.34	6454.942	6724.43	4126.857	4439.81	10254.54	10337.5	1332.71	1415.7	19.23206	20.41
2016-08-31	248.6673	268.09	725.458	663.69	18510.86	19864.08	5052.384	5213.22	16976.98	16887.4	21626.7	22976.88	2739.979	3085.49	6627.003	6781.51	4360.945	4438.22	9947.114	10592.69	1380.923	1367.9	26.3214	19.73
2016-09-30	254.131	257.49	648.4733	681.21	18445.39	18308.15	5114.088	5312	16299.81	16449.84	23571.32	22397.15	2734.403	3004.7	6838.718	6899.33	4243.715	4448.26	11261.93	10571.02	1374.283	1370.4	20.57177	20.28
2016-10-31	250.5946	255.93	681.6855	624.68	18386.7	18142.42	5346.092	5189.14	13474.28	17425.02	23744.59	22934.54	2750.158	3100.49	7054.077	6954.22	4429.289	4509.26	11269.75	10665.01	1390.489	1333.7	19.99119	18.82
2016-11-30	247.2186	254.26	575.2826	596.11	18050.31	19123.58	5259.743	5323.68	17318.63	18308.48	24986	22789.77	2869.544	3250.03	6974.227	6783.79	4528.046	4578.34	10011.65	10640.3	1393.663	1284	24.55129	17.44
2016-12-31	244.0944	260.01	609.8914	631.44	19029.4	19762.6	5248.598	5383.12	18892.96	19114.37	23314.4	22000.56	3067.85	3103.64	6904.044	7142.83	4525.951	4862.31	11126.85	11401.06	1274.791	1234.5	16.31517	17.03
2017-01-31	255.9346	268.09	504.4529	616.13	20105.88	19864.08	5052.384	5614.79	20666.52	19041.34	20889.04	23360.78	2956.227	3159.17	7323.371	7099.15	4805.754	4748.9	11509.62	11535.31	1253.22	1291.8	14.48957	18.69
2017-02-28	261.9541	270.06	646.7328	612.2	20180.03	20812.24	5540.573	5825.44	20278.81	19118.99	22496.07	23740.73	2899.153	3241.73	7253.082	7263.44	4811.121	4858.58	11880.06	11834.41	1268.916	1334.3	19.35819	19.68
2017-03-31	274.0384	280.64	599.3369	619.28	20858.37	20663.22	5809.108	5911.74	18237.35	18809.26	23927.63	24111.59	3012.862	3222.51	7331.365	7322.92	4995.769	5122.51	12438.02	12312.87	1309.97	1329.8	22.06407	19.48
2017-04-30	281.6635	287.21	597.96	628.24	20623.25	20940.51	5941.198	6047.61	18443.04	19202.5	25863.2	24615.13	2907.71	3154.66	7476.969	7203.94	5214.237	5267.33	12706.3	12428.01	1323.86	1347.1	17.48896	17.3
2017-05-31	287.1851	304.67	582.348	652.04	21124.87	21008.65	5954.22	6198.52	19989.67	19650.57	25712.7	25660.65	2909.29	3117.18	7345.46	7519.95	5275.166	5283.63	13179.11	12615.06	1332.327	1348.5	14.59737	18.56

### 3.4 시뮬레이션 결과

본 연구에서 제안하는 모형은 투자자별 투자 성향과 시장 상황에 따라 투입 변수를 바꿈으로써 투자자별 맞춤 자산 배분을 구현할 수 있다. 입력 변수로는 자산군 배분 비중, 고정 현금 비율, 상위 모멘텀 비율 3가지가 있다. 본 연구에서는 3가지 입력 변수들을 부분적으로 변환하며 P-MPAA 전략을 MPAA 및 동일가중 벤치마크와 백테스팅을 통해 성과 비교하였다.

시뮬레이션의 성과 지표로는 총 수익률(Total Return), 연 복리 수익률(Compound Annual Growth Rate), 연 변동성(Annual Standard Deviation), Sharpe Ratio, 직전 고점 대비 최대 낙폭을 의미하는 MDD(Maximum Drawdown), 고점 회복 기간(Years to Recovery), 전체 개월 수 중 수익이 발생한 달의 비율을 의미하는 % of Profit Months를 사용하였다. 무위험 수익률( $R_f$ )은 한국은행에서 고시하는 기준금리인 0.5%를 사용하였다.

$$Total\ Return = (1 + r_t)(1 + r_{t+1}) \dots (1 + r_{t+n})$$

$$Annual\ Std\ Dev = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

$$MDD = \text{최고점 대비 하락률}$$

$$Sharpe\ Ratio = \frac{E[R_{port} - R_f]}{Annual\ Std\ Dev}$$

$$Years\ to\ Recovery = \text{Max}(\text{직전 고점 회복기간}_i)$$

$$\% \text{ of Profit Months} = \frac{1}{N} \sum_{i=1}^N t \begin{cases} t = 1, & Return > 0 \\ t = 0, & Return \leq 0 \end{cases}$$

### 3.4.1 자산군 배분 비중 변경에 따른 시물레이션

시물레이션을 위한 입력 변수를 <표 7>과 같이 설정하였다. 첫 번째는 주식, 대체투자, 채권 군에 최대 33%씩 투자 가능하도록 설정하였고, 두 번째는 주식, 채권 군에 최대 40%, 대체투자 군에 20%가 투자 가능하도록 배분하였다. 세 번째는 주식, 채권 군에 최대 43%, 대체투자 군에 14%가 할당되도록 입력 변수들을 변경하며 백테스팅을 진행하였다. <표 8>은 1:1:1로 설정했을 때의 종목별 투자 비중을 나타낸 것이다. 백테스트 기간 동안 매월 말에 총 71회의 리밸런싱이 진행되었다.

<표 7> 시물레이션 자산군 배분 비중 변경값

	주식	대체투자	채권	상위모멘텀(%)	현금 비율
	(최대 투자 가능 비율)				
1	1	1	1	30	0.5
	(33%)	(33%)	(33%)		
2	2	1	2		
	(40%)	(20%)	(40%)		
3	3	1	3		
	(43%)	(14%)	(43%)		

<표 8> 종목별 리밸런싱 투자 비중

	코스피 200	코스닥	다우산업	나스닥	니케이 225	항생	상해종합	영국 FTSE100	프랑스 CAC40	독일DAX	금	은	WTI원유	천연가스	구리
Date															
2014-10-31	0.000000	0.069444	0.000000	0.069444	0.000000	0.000000	0.000000	0.074074	0.0	0.000000	0.104167	0.000000	0.000000	0.000000	0.055556
2014-11-30	0.000000	0.000000	0.071895	0.066667	0.071895	0.000000	0.000000	0.000000	0.0	0.000000	0.104167	0.000000	0.000000	0.000000	0.066667
2014-12-31	0.000000	0.000000	0.074074	0.000000	0.074074	0.000000	0.000000	0.000000	0.0	0.074074	0.104167	0.000000	0.000000	0.104167	0.000000
2015-01-31	0.000000	0.000000	0.000000	0.069444	0.074074	0.000000	0.069444	0.000000	0.0	0.000000	0.104167	0.075758	0.000000	0.000000	0.000000
2015-02-28	0.000000	0.074074	0.000000	0.000000	0.074074	0.000000	0.069444	0.000000	0.0	0.000000	0.107843	0.095238	0.000000	0.000000	0.000000
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
2020-04-30	0.000000	0.000000	0.074074	0.015873	0.000000	0.015873	0.000000	0.000000	0.0	0.000000	0.111111	0.000000	0.000000	0.000000	0.023810
2020-05-31	0.000000	0.069444	0.000000	0.063492	0.000000	0.000000	0.015873	0.000000	0.0	0.000000	0.111111	0.000000	0.000000	0.107843	0.000000
2020-06-30	0.000000	0.071895	0.000000	0.069444	0.000000	0.000000	0.000000	0.000000	0.0	0.069444	0.000000	0.111111	0.075758	0.000000	0.000000
2020-07-31	0.071895	0.069444	0.000000	0.074074	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	0.111111	0.000000	0.000000	0.000000	0.111111
2020-08-31	0.074074	0.071895	0.000000	0.071895	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	0.111111	0.111111	0.000000	0.000000	0.000000

1) 주식 : 대체투자 : 채권 = 1(33%) : 1(33%) : 1(33%)



<그림 10> 주식:대체투자:채권 = 1:1:1 누적수익률 비교

<표 9> 주식:대체투자:채권 = 1:1:1 성과비교

	P-MPAA	MPAA	동일가중
Total Return	35.73%	24.81%	38.02%
CAGR	5.29%	3.81%	5.59%
Annual Std Dev	5.18%	4.26%	8.76%
Sharpe Ratio	0.78	0.65	0.51
MDD	-7.29%	-6.10%	-16.3%
Years to Recovery	1.5년	1.5년	1.9년
% of Profit Months	62.8%	60.0%	62.8%

2) 주식 : 대체투자 : 채권 = 2(40%) : 1(20%) : 2(40%)



<그림 11> 주식:대체투자:채권 = 2:1:2 누적수익률 비교

<표 10> 주식:대체투자:채권 = 2:1:2 성과비교

	P-MPAA	MPAA	동일가중
Total Return	40.22%	28.35%	38.02%
CAGR	5.88%	4.3%	5.59%
Annual Std Dev	4.3%	4.29%	8.76%
Sharpe Ratio	1.05	0.74	0.51
MDD	-5.93%	-5.47%	-16.3%
Years to Recovery	1.0년	2.5년	1.9년
% of Profit Months	68.5%	64.2%	62.8%

2) 주식 : 대체투자 : 채권 = 3(43%) : 1(14%) : 3(43%)



<그림 12> 주식:대체투자:채권 = 3:1:3 누적수익률 비교

<표 11> 주식:대체투자:채권 = 3:1:3 성과비교

	P-MPAA	MPAA	동일가중
Total Return	42.11%	29.84%	38.02%
CAGR	6.11%	4.51%	5.59%
Annual Std Dev	4.03%	4.42%	8.76%
Sharpe Ratio	1.16	0.76	0.51
MDD	-5.35%	-5.58%	-16.3%
Years to Recovery	1.0년	2.5년	1.9년
% of Profit Months	70%	64.2%	62.8%

전체 자산 중에 주식, 채권 군에 최대 투자 가능 비중이 33%~43%, 대체투자 군에는 14%~33%가 투자 가능하도록 3가지 사례를 바탕으로 분석하였다. 3가지 사례에서 P-MPAA는 동일가중으로 구성한 벤치마크와 MPAA 전략보다 뛰어난 성과를 보였다. 수익률과 변동성은 상충관계를 가지므로 일부 사례에서는 P-MPAA 전략이 MPAA보다 큰 변동성을 보이고, 높은 수익률을 얻기도 하였다. 다만, 모든 예시에서 P-MPAA 전략이 Sharpe Ratio, Years to Recovery, % of Profit Months에서 높은 수치를 보였다.


### 3.4.2 고정 현금 비율 변경에 따른 시뮬레이션

시뮬레이션을 위한 입력 변수를 <표 12>와 같이 설정하였다. 자산군 배분 비중, 상위 모멘텀을 고정시키고 고정 현금 비율을 바꾸었다. 투자자의 위험회피성향에 따라 현금 비율을 설정하여 원하는 비중을 설정할 수 있다. 현금 비율이 0.1은 공격적 성향의 투자자, 현금비율 0.5는 중립적인 투자자, 현금비율 1은 보수적인 투자자라 가정하여 시뮬레이션을 진행하였다.

<표 12> 고정 현금 비율 변경값

	주식	대체투자	채권	상위모멘텀(%)	현금 비율
	(최대 투자 가능 비율)				
1	3 (43%)	1 (14%)	3 (43%)	30	0.1(공격적)
2					0.5(중립적)
3					1(보수적)

1) 현금 비율 = 0.1(공격적)




<그림 13> 현금 비율 = 0.1 누적수익률 비교

<표 13> 현금 비율 = 0.1 성과비교

	P-MPAA	MPAA	동일가중
Total Return	59.40%	35.61%	38.02%
CAGR	8.19%	5.28%	5.59%
Annual Std Dev	5.95%	6.57%	8.76%
Sharpe Ratio	1.09	0.62	0.51
MDD	-7.25%	-8.74%	-16.3%
Years to Recovery	1.1년	2.5년	1.9년
% of Profit Months	70.0%	62.8%	62.8%



2) 현금 비율 = 0.5(중립적)




<그림 14> 현금 비율 = 0.5 누적수익률 비교

<표 14> 현금 비율 = 0.5 성과비교

	P-MPAA	MPAA	동일가중
Total Return	42.11%	29.84%	38.02%
CAGR	6.11%	4.51%	5.59%
Annual Std Dev	4.03%	4.42%	8.76%
Sharpe Ratio	1.16	0.76	0.51
MDD	-5.35%	-5.58%	-16.3%
Years to Recovery	1.0년	2.5년	1.9년
% of Profit Months	70.0%	64.2%	62.8%

3) 현금 비율 = 1(보수적)



<그림 15> 현금 비율 = 1 누적수익률 비교

<표 15> 현금 비율 = 1 성과비교

	P-MPAA	MPAA	동일가중
Total Return	32.50%	25.11%	38.02%
CAGR	4.87%	3.85%	5.59%
Annual Std Dev	2.92%	3.1%	8.76%
Sharpe Ratio	1.24	0.90	0.51
MDD	-3.85%	-3.76%	-16.3%
Years to Recovery	1.0년	1.5년	1.9년
% of Profit Months	70.0%	65.7%	62.8%

현금 비율을 변경하여 분석한 3가지 모든 사례에서 P-MPAA 전략이 동일 가중 벤치마크, MPAA 전략 모든 지표에서 뛰어난 성과를 보였다. 이는 특정 현금 비율에 최적화된 전략이 아니라는 점을 내포하고 있다. 투자자 위험회피성향에 맞게 어떠한 현금 비율을 사용하더라도 안정적인 위험관리와 상대적으로 높은 수익률을 추구할 수 있다.

### 3.4.3 상위 모멘텀 변경에 따른 시뮬레이션


시뮬레이션을 위한 입력 변수를 <표 16>과 같이 설정하였다. 자산군 배분 비중, 고정 현금 비율을 고정시키고 상위 모멘텀에 의해 선정되는 주식, 대체투자, 채권 종목수를 변경하면서 분석하였다.

첫 번째는 상위 모멘텀 30%를 설정하여 매달 말 리밸런싱 시점마다 평균 모멘텀을 계산하여 평균 모멘텀이 높은 주식 3종목, 대체투자 2종목, 채권 1종목 선택하였다. 두 번째는 상위 모멘텀 50%를 설정하여 매달 말 주식 5종목, 대체투자 3종목, 채권 2종목을 선택하였다. 세 번째는 상위 모멘텀 70%를 설정하여 매달 말 주식 7종목, 대체투자 4종목, 채권 2종목을 선택하여 시뮬레이션을 진행하였다.

<표 16> 상위 모멘텀 변경값

	주식	대체투자	채권	상위모멘텀(%)			현금 비율
	(최대 투자 가능 비율)			주식	대체투자	채권	
1	3 (43%)	1 (14%)	3 (43%)	3	2	1	0.5
2				5	3	2	
3				7	4	2	

1) 상위모멘텀 30%(주식 3종목, 대체투자 2종목, 채권 1종목)




<그림 16> 상위모멘텀 30% 누적수익률 비교

<표 17> 상위모멘텀 30% 성과비교

	P-MPAA	MPAA	동일가중
Total Return	42.11%	29.84%	38.02%
CAGR	6.11%	4.51%	5.59%
Annual Std Dev	4.03%	4.42%	8.76%
Sharpe Ratio	1.16	0.76	0.51
MDD	-5.35%	-5.58%	-16.3%
Years to Recovery	1.0년	2.5년	1.9년
% of Profit Months	70%	64.2%	62.8%

2) 상위모멘텀 50%(주식 5종목, 대체투자 3종목, 채권 2종목)




<그림 17> 상위모멘텀 50% 누적수익률 비교

<표 18> 상위모멘텀 50% 성과비교

	P-MPAA	MPAA	동일가중
Total Return	33.05%	23.17%	38.02%
CAGR	4.94%	3.58%	5.59%
Annual Std Dev	3.51%	3.54%	8.76%
Sharpe Ratio	1.05	0.72	0.51
MDD	-5.24%	-6.33%	-16.3%
Years to Recovery	1.3년	2.5년	1.9년
% of Profit Months	72.8%	67.1%	62.8%


3) 상위모멘텀 70%(주식 7종목, 대체투자 4종목, 채권 2종목)



<그림 18> 상위모멘텀 70% 누적수익률 비교

<표 19> 상위모멘텀 70% 성과비교

	P-MPAA	MPAA	동일가중
Total Return	31.91%	23.24%	38.02%
CAGR	4.79%	3.59%	5.59%
Annual Std Dev	3.71%	3.29%	8.76%
Sharpe Ratio	0.96	0.78	0.51
MDD	-4.46%	-4.91%	-16.3%
Years to Recovery	1.1년	2.0년	1.9년
% of Profit Months	68.5%	68.5%	62.8%



<그림 19> 상위 모멘텀 50% 종목 리밸런싱 투자 비중

위에서 3가지 사례로 상위 모멘텀 비율 변경을 통해 성과 분석을 진행하였다. 비율 변경으로 자산군별로 매월 투자되는 종목수를 변경해보았고, 분석 결과 상위 30%, 50%, 70% 모두 Sharpe Ratio를 비롯하여 대부분의 성과 지표에서 LSTM을 활용한 P-MPAA 전략이 MPAA 및 동일가중 벤치마크보다 뛰어난 성과를 보였음을 확인하였다. 또한, 특정 상위 모멘텀 값이 과최적화로 인해 벤치마크 대비 높은 수치를 보인 것이 아님을 확인하였다. <그림 19>는 상위 모멘텀 50%로 리밸런싱을 진행하였을 때, 매월 선정되는 종목과 투자 비중을 나타낸 것이다. 매월 각 자산군들의 모멘텀에 따라서 리밸런싱이 진행됨을 알 수 있었고, MMF는 35%~60% 비중 내에서 변경되고 있음을 확인하였다.

## 제 4장 결론 및 향후 연구

### 4.1 결론

본 연구에서는 딥러닝 LSTM 모델을 활용하여 한 달 뒤 주가를 예측하였고, 예측된 주가를 바탕으로 모멘텀 전략을 개선한 MPAA 자산 배분 전략을 응용하여 포트폴리오를 구성하였다. 기존 모멘텀 기반의 자산 배분 전략은 과거 모멘텀을 이용하여 미래에도 모멘텀이 이어질 것이라는 가정하에 출발한다. 본 연구에서는 한 달 뒤 주가를 예측하여 예측 모멘텀을 사용하는 새로운 모델을 제시하였다. 실증분석을 위해 자산군 배분 비중, 고정 현금 비율, 상위 모멘텀 비율 3가지 입력 변수를 각각 3가지 사례를 통하여 특정 값이 과최적화의 문제점을 내포하고 있는지 살펴보았다. 대부분의 실증 분석에서 LSTM을 활용한 P-MPAA 자산 배분 전략이 과거 모멘텀을 사용한 MPAA 전략, 동일가중으로 구성된 벤치마크보다 변동성, 수익률, 손실 감내 기간 등에서 우수한 결과값을 보였다. 최근 자산운용업계의 트렌드가 액티브 펀드에서 패시브 펀드로 옮겨가면서 ETF를 활용한 EMP의 시장규모가 점차 확대되고 있다. 또한, 인공지능의 기술이 발달되면서 여러 로보 어드바이저 회사들은 머신러닝, 딥러닝 기술을 자산 배분 전략에 도입하고자 노력하고 있다. 이에 본 연구에서는 딥러닝 LSTM 모델과 자산 배분 모형 MPAA를 결합한 실증 분석을 통해 금융업계에서 활용가치가 있음을 증명하였다.

### 4.2 향후 연구

본 연구에서 아쉬웠던 점은 매월 말 리밸런싱을 가정하였기에 월봉 데이터를 이용하여 주가를 예측하였다. 금융데이터 특성상 시계열 길이가 짧은 문제점이 있다. 최대한 시계열이 긴 데이터를 이용하기 위해 대체 지수를



하였음에도 236개의 시퀀스 데이터를 사용할 수밖에 없었다. 특히, 지도학습 모형 특성상 훈련 학습 기간이 포함되어야 하기 때문에 백테스팅이 가능한 기간이 더욱 짧아지게 되었다. 이러한 문제점을 개선하기 위해 분봉, 일봉, 주봉 등의 시퀀스 데이터를 활용하여 모형의 예측 정확도를 높이는 작업이 필요할 것으로 보인다.

또한, 본 연구에서는 LSTM 입력 변수로 DataGuide5에서 얻을 수 있는 시가, 종가, 저가, 고가, 1개월 증가 평균, 전월대비 수익률을 사용하였다. 향후 추가 연구에서는 외국인 및 기관의 순매수, 변동성, 기술적 지표, 텍스트 마이닝을 활용한 정치 및 경제 이슈 발생 유무를 입력 변수로 활용한다면 더 개선된 연구 성과를 얻을 수 있을 것으로 보인다.



## 참고문헌

- [1] 김현일, 한건연, 이재영 (2020), “LSTM 모형과 로지스틱 회귀를 통한 도시침수 범위의 예측,” 대한토목학회, Vol.40, No.3, p.273-283.
- [2] 송한진 (2020), “TDF 운용에서 변동성 예측을 활용한 자산 배분 전략에 관한 연구,” 국민대학교 비즈니스IT전문대학원.
- [3] 이성규, Systrader79 (2018), “실전 ETF투자 매뉴얼, 주식투자 ETF로 시작하라,” 이레미디어.
- [4] 전균 (2016), “ETF Managed Portfolio”, 삼성증권.
- [5] 주형길, 이기승 (2019), “LSTM 순환신경망을 이용한 초음파 도플러 신호의 음성 패러미터 추정,” 한국음향학회, Vol.38, No.4, p.433-441.
- [6] 차은아 (2017), “한국 주식시장에서 시계열 모멘텀과 듀얼 모멘텀 전략에 대한 실증연구,” 한국과학기술원.
- [7] Antonacci, G. (2012), “Risk Premia Harvesting Through Dual Momentum,” Journal of Management & Entrepreneurship, Vol.2, No.1, p.27-55.
- [8] Hurst, B., Y. H. Ooi and L. H. Pedersen (2013), “Demystifying Managed Futures”, Journal Of Investment Management, Vol.11, No.3, p.42-58.

- [9] Faber, M. (2007), "A Quantitative Approach to Tactical Asset Allocation," The Journal of Wealth Management, Vol.9, No.4, p.69-79.
- [10] Fama, E. F. (1962), "Random Walks in stock-Market Prices," School of Business University of Chicago.
- [11] Fama, E. F. and K. R. French (1962), "The Cross-Section of Expected Stock Returns," The Journal of Finance, Vol.47, No.2, p.427-465.
- [12] Fama, E.F. and K. R. French (1966), "Multifactor Explanations of Asset Pricing Anomalies," The Journal of Finance, Vol.51, No.1, p.55-84.
- [13] Hochreiter, S. and J. Schmidhuber (1997) "LongShort-Term Memory," Neural Computation, Vol.9, No.8, p.1735-1780.
- [14] Jegadeesh, N. and S. Titman (1993), "Returns of Buying Winners and Selling Losers: Implications for Stock Market Efficiency," The Journal of Finance, Vol.48, No.1, p.65-91.
- [15] Keller, W. J. and J. W. Keuning (2016), "Protective Asset Allocation(PAA): A simple Momentum-Based Alternative for Term Deposits," SSRN Electronic Journal.
- [16] Lintner, J (1965), "The Valuation of risk: assets and the selection of risky investments in stock portfolio and captial budgets," Review of Economics and Statistics, Vol.47, No.1, p.13-37.

- [17] Markowitz, H. M. (1952), "Portfolio Selection," Journal of Finance, Vol.7, No.1, p.77-91.
- [18] Mossin, J (1966), "Equilibrium in a Capital Asset Market," Econometrica, Vol.34, No.4, p.768-783.
- [19] Sharpe, W. F. (1964), "Capital Asset Prices: A theory of Market equilibrium under conditions of risk," The Journal of Finance, Vol.19, No.3, p.425-442.



## Abstract

# Dynamic Asset Allocation Model Design and Performance Analysis using Deep Learning LSTM

by Park, Jong Chun

Department of Trading Systems  
Graduate school of Business-IT  
Kookmin University,  
Seoul, Korea

In the middle of the sustained low interest rate and financial crises, the investing model moved from active management to passive management, contributing to dramatic growth in the ETF industry. Among them, EMP, an asset allocation strategy focused on low-cost competition based on ETFs, has established itself as a representative asset management tool in the US and Europe. In the domestic financial market, a number of Robo-Advisor firms are achieving rapid growth on the basis of EMP and are evolving passive management approaches by integrating AI innovations such as machine learning and deep learning into EMP.

The theoretical history of passive management has been built into a number of efficient market models, such as the CAPM asset pricing model, based on Markowitz's modern portfolio theory. However, abnormal phenomena contradictory to efficient market theory have been consistently found in the stock market, and the momentum effect has been a representative anomaly across numerous analytical analyzes. Among several momentum analyses, Systrader79 and Sungkyu Lee proposed the MPAA approach, a complex asset allocation model that strengthened the dual momentum. The MPAA strategy, though, continues with the

expectation that the momentum measured in the past and present will persist in the future. This suggests a problem because if the historical pattern does not translate to the future, the outcome will be different from the projected value.

Therefore, in this study, I plan to enhance this by predicting future market prices using the LSTM circulatory neural network suitable for time series data among deep learning models. At point T, the LSTM was used to forecast the stock price a month later (T+1) and the portfolio was built using the dynamic asset allocation model of the MPAA strategy based on the projected stock price. As a result, numerous simulation analyzes have demonstrated changes in various risk indicators, such as Sharp Ratio and MDD, relative to benchmarks consisting of equal weight and current MPAA strategies.

**Keyword** : ETF, EMP, Deep Learning, LSTM, Dynamic Asset Allocation, MPAA

